

01 / SEEING & RECOGNITION

본다는 것은, 분류한다는 것.

인간의 시각에서 출발해 CNN의 아이디어에 도착하는 여정.

CNN ① · 개념으로 읽는 이미지 분류

90분 · 관찰, 도식, 손계산, 토론

AIM DEEP LEARNING STUDY / 2026



작은 단서를 모아 하나의 이름을 붙이기.

SESSION MAP / 90 MIN

오늘은 무엇을 “이해”할까?

코드를 실행하는 능력에서 한 걸음 더 들어가, 이 구조가 필요한 이유를 설명한다.

첫 질문 컵은 색과 위치가 바뀌어도 왜 컵인가? 우리는 무엇을 보존하고 무엇을 무시하는가?

중간 질문 숫자로 이루어진 이미지에서 작은 패턴을 찾고, 더 큰 단서로 조합하려면 어떤 연산이 필요할까?

마지막 질문 정답을 알려 주면 필터는 어떻게 달라질까? 높은 점수와 올바른 이해는 같은가?

00-05	함께 볼 질문	5분
05-15	물체를 알아보는 단서	10분
15-30	지역성과 시각 연구	15분
30-50	필터·반응 지도·요약	20분
50-65	표현의 조합과 학습	15분
65-80	종이 위의 합성곱 활동	15분
80-90	개념 연결과 출구 질문	10분

코딩 실습은 별도 선택 확장입니다. 이 시간표는 개념 수업만으로 90분을 구성합니다.

Remember 도입 5 + 시각 10 + 설계 배경 15 + 합성곱 20 + 조합·학습 15 + 활동 15 + 정리 10 = 90분.

01 / NOTICE BEFORE NAMING

이것을 컵이라고 부른 순간.

이름을 말하기는 쉽다. 그 이름에 도달한 단서를 말하기는 조금 더 어렵다.

손잡이, 안이 빈 몸체, 위쪽 입구가 보인다. 하지만 손잡이가 없는 컵도 있다. 우리는 단서 하나를 반드시 충족해야 하는 체크리스트만으로 모든 물체를 분류하지는 않는다.

사물의 형태뿐 아니라 장면과 사용 경험도 판단에 영향을 줄 수 있다. 여기서는 그중 **이미지에서 읽을 수 있는 시각 단서**를 떼어 생각해 보자.



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember “무엇인가?”와 “무엇을 보고 그렇게 판단했는가?”는 다른 질문이다.

함께 생각하기 30초 관찰: 컵의 단서를 세 가지 쓰고, 각 단서가 없는 컵을 떠올려 보자.

02 / VARIATION & CONSTANCY

다른 모습, 같은 범주.

픽셀은 달라져도 우리가 붙이는 이름은 그대로인 경우가 많다.

같은 컵도 조명, 크기, 시점, 가림에 따라 전혀 다른 영상이 된다. 이미지 분류는 이 차이 중에서 **범주와 무관한 변화**를 어느 정도 넘어서는 일이다.

반대로 손잡이나 몸체의 배치를 무작정 바꾸면 정체성이 달라질 수 있다. 좋은 표현은 모든 차이를 없애는 것이 아니라, 판단에 필요한 차이를 남긴다.



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 무시할 변화와 보존할 변화 사이에서 표현을 설계한다.

함께 생각하기 색 변화·뒤집기·가리기 중 어떤 변화까지 같은 범주로 볼 수 있을까?


03 / PARTS & RELATIONS

전체는 단서의 단순한 합일까?

귀 두 개와 눈 두 개만 있다고, 모든 배치가 고양이 얼굴이 되는 것은 아니다.

물체를 알아보려면 어떤 부분이 있는지와 그 부분들이 어떻게 놓였는지를 함께 생각해야 한다. **부분의 존재**와 **부분의 관계**는 같은 정보가 아니다.

CNN은 지역 패턴을 여러 층에 걸쳐 조합할 수 있다. 그렇다고 특정 층이 반드시 귀, 다음 층이 반드시 얼굴을 뜻하는 것은 아니다. 이런 이름은 구조를 이해하기 위한 설명용 단계다.



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember “선 → 부분 → 물체”는 유용한 직관이며, 모든 뉴런의 실제 의미표는 아니다.

함께 생각하기 눈과 귀의 위치를 바꾸면 어떤 정보가 남고 어떤 정보가 달라질까?

04 / FROM LIGHT TO ARRAYS

컴퓨터가 처음 받는 것은 숫자다.

“컵”이라는 이름이나 “손잡이”라는 설명은 입력 파일 안에 없다.

디지털 이미지는 위치별 밝기나 색을 수치로 표현한다. RGB라면 한 위치에 세 채널의 값이 있고, 이웃한 위치에도 같은 구조의 숫자가 놓인다.

라벨은 이미지 바깥에서 붙인 감독 신호다. 모델은 숫자 배열과 라벨의 예를 보며 연결을 학습한다. 사람이 사물을 경험하며 배우는 과정 전체와는 다르다.



18	18	23	26	25
19	38	178	191	25
25	41	184	204	171
29	39	163	186	151
18	22	39	45	27

한 채널을 확대한 숫자 배열

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 이미지의 숫자와 범주의 이름 사이를 연결하는 중간 표현이 필요하다.

함께 생각하기 픽셀 하나만 보았을 때와 주변 3×3 영역을 보았을 때 알 수 있는 것이 어떻게 다를까?


05 / LOCAL STRUCTURE

왜 이웃한 픽셀끼리 볼까?

한 픽셀의 값보다 주변 픽셀과의 차이가 경계와 방향을 드러낸다.

주변 값이 함께 밝아지는지, 한쪽만 어두운지를 보면 선이나 경계의 단서를 얻을 수 있다. 가까운 위치들 사이의 관계를 반복해서 계산할 이유가 생긴다.

이미지를 길게 펼쳐도 고정된 순서라면 정보를 복원할 수 있다. Flatten의 문제는 정보가 마법처럼 사라지는 것이 아니라, 전결합 구조가 **2차원 이웃 관계를 특별히 활용하지 않는다**는 점이다.



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 지역 연결은 이미지에 대한 가정을 모델 구조에 넣는 방법이다.

함께 생각하기 영상과 달리 “이웃한 인덱스”에 의미가 없는 데이터라면 같은 가정이 적절할까?


06 / THE TEMPLATE PROBLEM

정답 사진 한 장과 비교하면 안 될까?

같은 컵이 한 칸만 이동해도 픽셀끼리 직접 비교한 차이는 커질 수 있다.

사진 한 장을 정답 도장처럼 저장하면 다른 조명, 배경, 크기의 컵마다 새 도장이 필요하다. 가능한 모습을 모두 외우는 방식은 쉽게 커진다.

대신 여러 물체에서 반복되는 작은 단서를 찾아 재사용하자. 둥근 테두리나 세로 경계는 컵뿐 아니라 다른 사물에도 나타날 수 있다.



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 하나의 완성된 사진보다, 여러 장면에 재사용할 수 있는 단서를 학습한다.

함께 생각하기 사진 전체를 외우는 방식이 통할 만한 아주 제한된 상황도 떠올려 보자.

07 / BIOLOGICAL INSPIRATION

시각 연구에서 빌려 온 질문.

어떤 세포는 시야의 일부, 그리고 특정 방향의 자극에 더 반응했다.


Hubel과 Wiesel은 고양이 시각피질에서 국소적인 수용 영역과 방향에 따른 반응 특성을 연구했다. 여기서 중요한 것은 뇌 안에 작은 “고양이 사진”이 저장되어 있다는 이야기가 아니다.

전체 장면을 한 번에 다루지 않고 지역 자극에 선택적으로 반응한다는 관찰이 계산 모형을 생각하는 데 영감을 주었다. 아래 반응 막대는 원 논문 측정값이 아닌 개념도다.

자극 방향



예시 반응



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 생물학적 관찰 → 계산 아이디어. 두 단계를 구분해서 읽는다.


08 / RECEPTIVE FIELD

한 위치를 보는 창: 수용 영역.

한 출력의 반응에 영향을 줄 수 있는 입력 영역을 먼저 생각하자.

작은 창 안에 경계가 들어오면 반응하고, 창 바깥의 변화는 그 연산에 직접 들어오지 않는다. 이처럼 제한된 입력 범위를 **수용 영역**이라는 언어로 설명할 수 있다.

CNN의 수용 영역은 연결 구조와 연산으로 계산한다. 생물학에서 실험으로 측정하는 수용 영역과 완전히 같은 대상은 아니지만, 지역성이라는 연결점을 제공한다.



입력 중 영향을 주는 영역

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 한 번에 작은 영역을 보더라도, 층을 쌓으면 더 넓은 영역의 영향을 받을 수 있다.

09 / A CAREFUL BRIDGE

뇌의 복제품이 아니라, 설계의 힌트.

지역성·단계적 조합·위치 변화에 대한 강건함을 계산 가능한 구조로 옮긴다.

Fukushima의 Neocognitron은 계층적 패턴 인식의 중요한 선행 모형이다. 이후 학습 가능한 합성곱 구조와 역전파를 결합한 모델이 문서 인식 등에 적용됐다.

현대 CNN의 정확한 가중치 공유나 역전파를 인간 뇌가 그대로 수행한다고 결론낼 수는 없다. 인간 시각에는 반복 처리, 주의, 경험과 장면 해석 등 여기서 다루지 않는 과정도 있다.



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember CNN은 시각 처리의 일부 아이디어를 공학적으로 활용한 모델 계열이다.

10 / LOCAL · SHARED · HIERARCHICAL

CNN의 세 가지 설계 선택.

작게 보고, 같은 기준을 옮겨 쓰고, 그 결과를 다시 조합한다.

지역 연결 주변 픽셀에서 작은 패턴을 찾는다. 전체 이미지의 모든 위치와 바로 연결할 필요를 줄인다.

가중치 공유 같은 필터를 여러 위치에 적용한다. 왼쪽의 경계와 오른쪽의 경계에 같은 검출 기준을 쓴다.

계층적 조합 앞에서 찾은 패턴 지도를 다음 층의 입력으로 사용한다.

01

LOCAL

작게 연결

02

SHARED

같은 기준 재사용

03

HIERARCHICAL

반응들을 다시 조합

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 이 세 선택이 모델의 계산 방식과 학습할 가중치 수를 바꾼다.

11 / CONVOLUTION, ONE WINDOW

필터는 “무엇과 닮았나”를 묻는다.

패치와 필터를 같은 위치끼리 곱하고 더한다. 결과는 한 칸의 반응값이다.

예를 들어 왼쪽에 -1, 오른쪽에 +1을 둔 필터는 양쪽 밝기 차이에 반응한다. 필터의 부호를 뒤집으면 반응의 부호도 바뀐다.

이 반응값은 아직 컵의 확률이 아니다. 지금 위치가 특정 패턴과 얼마나 맞는지를 나타내는 중간 수치다. 실제 학습에서는 필터 값도 데이터에 맞춰 바뀐다.

0	0	1		-1	0	1	
0	0	1	×	-1	0	1	=
0	0	1		-1	0	1	3

현재 패치
필터

$$(-0+1) + (-0+1) + (-0+1) = 3$$

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 패치 × 필터의 합 → 특징 맵의 한 칸. 이 과정을 위치마다 반복한다.

함께 생각하기 왼쪽과 오른쪽 밝기를 바꾸면 출력의 부호는 어떻게 될까?


12 / FEATURE MAP

한 칸의 반응을 지도로 모으면.

같은 질문을 이미지의 여러 위치에 던져, 반응이 생긴 위치를 남긴다.

웹에서는 슬라이더로 필터 창을 옮겨 보자. 입력이 그대로여도 창이 지나가는 패치가 달라져 출력값이 달라진다. **같은 필터, 다른 위치**라는 점이 핵심이다.

출력 특징 맵은 답 하나가 아니라 위치를 가진 지도다. 밝은 칸은 이 예제 필터가 강하게 반응한 곳이지, 모든 의미에서 중요한 위치라는 뜻은 아니다.



$$\text{padding} = 0 \cdot \text{stride} = 1 \cdot \text{bias} = 0$$

숫자는 위 입력으로 직접 계산한 값입니다. 필터는 위치가 바뀌어도 같습니다.

Remember PDF의 고정 그림은 첫 위치의 계산을 보여 준다. 웹에서는 모든 위치를 직접 탐색할 수 있다.

함께 생각하기 창이 평평한 영역과 경계 영역을 지날 때 반응을 비교해 보자.


13 / CHANNELS

필터 여러 개는 질문 여러 개다.

가로 경계, 세로 경계, 다른 색 조합에 각각 반응할 여지를 만든다.

필터 하나는 하나의 출력 채널을 만든다. 여러 필터를 쓰면 같은 이미지를 서로 다른 관점에서 계산한 여러 장의 특징 맵이 생긴다.

RGB 입력에서는 각 필터가 세 입력 채널을 함께 사용한다.
입력의 색 채널과 출력의 특징 채널은 역할이 다르다. 출력 채널마다 사람이 읽을 수 있는 이름이 반드시 붙는 것도 아니다.



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 입력 채널은 받은 표현의 축, 출력 채널은 새로 만든 반응 지도의 축이다.

14 / WEIGHT SHARING

어디에 있든 같은 기준으로.

같은 모양의 단서는 이미지의 왼쪽에서도 오른쪽에서도 쓸모가 있다.

위치마다 서로 다른 필터를 배워야 한다면 비슷한 패턴을 많은 위치에서 다시 학습해야 한다. 가중치 공유는 하나의 검출 기준을 여러 위치에 적용하도록 구조를 제한한다.

예를 들어 흑백 입력에서 3×3 필터 16개와 bias 16개는 총 160개 가중치를 사용한다. 출력 맵의 모든 칸에 별도 필터가 생기는 것이 아니다.

-1	0	1	-1	0	1	-1	0	1
-1	0	1	-1	0	1	-1	0	1
-1	0	1	-1	0	1	-1	0	1

9개의 값, 위치마다 재사용

출력 위치가 늘어도 새 필터가 생기는 것은 아니다.

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 표현력에 제약을 주는 대신, 이미지에 유용한 규칙을 구조에 넣는다.

함께 생각하기 같은 얼굴의 눈이 항상 정해진 위치에만 있어야 한다면, 어떤 가정이 달라질까?


15 / NONLINEARITY

왜 반응을 그냥 쌓지 않을까?

선형 계산만 연달아 연결하면, 전체도 하나의 선형 계산으로 합쳐진다.

ReLU는 음수 반응을 0으로 두고 양수는 통과시킨다. 단순한 규칙이지만 입력에 따라 어떤 반응이 전달될지를 바꾼다.

이 비선형 변환이 사이에 들어가면 층을 여러 번 거치는 것이 하나의 큰 선형 필터와 달라질 수 있다. ReLU가 생물학적 뉴런의 모든 성질을 모사한다고 해석할 필요는 없다.



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 필터는 패턴을 계산하고, 비선형성은 그 계산을 조합하는 방식을 풍부하게 한다.

함께 생각하기 -2, 0, 3을 ReLU에 넣으면 무엇이 남을까?

16 / POOLING

세부 위치를 덜 기억하는 요약.

“어디에 정확히 있었나”를 조금 버리고 “근처에 있었나”를 남긴다.

Max pooling은 작은 영역의 반응 중 가장 큰 값을 남긴다.
반응이 영역 안에서 조금 움직여도 같은 요약값이 나올 수 있다.

그러나 최대가 아닌 반응과 정밀한 위치는 사라진다. 작은 글자나 가는 선에서는 이 손실이 중요할 수 있다. pooling을 썼다는 사실만으로 완전한 이동 불변성이 보장되지 않는다.

1

4

2

3



MAX → 4

가장 큰 반응만 남김

AVERAGE → 2.5

전체 크기를 평균으로 요약

원래 위치 정보

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 요약의 이점과 정보 손실은 함께 온다.

함께 생각하기 [1, 4; 2, 3]의 max와 average는 각각 얼마인가?

17 / BUILDING CONTEXT

작은 창들이 연결되면 더 넓게 본다.

3×3을 보는 출력을 다시 3×3으로 모으면, 원래 입력의 더 넓은 영역이 영향을 준다.

stride 1의 3×3 합성곱 두 층을 거친 한 출력은 이론적으로 원래 입력의 5×5 영역을 참조한다. 세 층이면 7×7로 넓어진다.


이것은 단순히 큰 창 하나와 동일한 계산이라는 뜻은 아니다. 중간에 여러 채널과 비선형 변환이 패턴 조합을 다르게 만든다.



한 층 / 3×3



두 층 / 5×5



세 층 / 7×7

stride 1 · dilation 1의 3×3 합성곱을 연결한 예

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 넓은 문맥은 작은 지역 계산들을 연결해서도 만들어진다.

함께 생각하기 이미지가 작을 때 공간 해상도를 너무 일찍 줄이면 무엇을 놓칠까?


18 / FROM FEATURES TO A DECISION

패턴 지도에서 범주 점수까지.

분류기는 여러 특징의 조합이 각 범주를 얼마나 지지하는지 계산한다.

앞부분은 이미지에서 특징 맵을 만든다. 뒷부분은 그 정보를 모아 컵, 병, 그릇 같은 후보별 점수를 만든다. 이 두 부분은 보통 같은 학습 목표 아래 함께 조정된다.

한 특징이 곧 한 범주는 아니다. 둥근 입구는 컵과 그릇 모두에 나타날 수 있다. 분류는 여러 단서의 조합을 사용하는 계산이다.



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 입력 → 지역 반응 → 조합된 표현 → 클래스 점수.


19 / LOGITS & SOFTMAX

“0.8”은 모델 안에서 어떤 뜻일까?

점수를 확률 합이 1인 상태로 바꾸어, 준비된 후보들 사이의 상대적 선택을 표현한다.

softmax는 logits라는 점수들을 양수로 바꾸고 합이 1이 되게 정규화한다. 예제의 [2, 1, 0]은 약 [0.665, 0.245, 0.090]이 된다.

목록에 없는 물체가 들어와도 모델은 준비된 후보 중에 높은 값을 줄 수 있다. 또한 0.8이라는 값이 현실에서 항상 80%의 정답률과 맞아떨어지는 것은 아니다.



logits

합이 1인 상대적 확률

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 높은 점수는 관측과 평가를 대신하는 보증서가 아니다.

함께 생각하기 컵·병·그릇만 배운 모델에 신발 사진을 넣으면 어떤 문제가 생길까?


20 / LEARNING FROM FEEDBACK

필터를 사람이 모두 그려 주지는 않는다.

우리가 정하는 것은 구조와 학습 목표다. 많은 필터 값은 예시를 보며 조정된다.

처음에는 무작위에 가까운 필터로 예측한다. 정답 라벨과 예측을 비교해 손실을 계산하고, 손실을 줄이는 방향으로 가중치를 조금 수정한다.

이 과정을 반복하면 데이터와 목표에 유용한 패턴이 강화될 수 있다. 모델에게 “손잡이를 찾아라”라고 직접 명령하지 않아도, 분류에 도움이 되는 중간 표현을 배울 여지가 생긴다.



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 설계자는 학습할 공간을 만들고, 데이터와 목표가 그 안의 해를 밀어 간다.

함께 생각하기 라벨과 상관없는 배경이 항상 함께 나타나면 무엇을 학습할 수도 있을까?


21 / LOSS & GRADIENT

틀린 이유를 숫자로 전달한다.

손실은 잘못의 크기, gradient는 가중치를 바꿨을 때 그 손실이 변하는 방향을 알려 준다.

정답 클래스의 예측 확률이 0.8이면 $-\log(0.8)$ 은 약 0.223이다.
같은 정답에 0.1을 주었다면 약 2.303으로 더 큰 손실을 받는다.

역전파는 출력 쪽의 손실 변화를 연쇄 법칙으로 앞쪽 가중치까지 계산한다. 사람의 반성이나 뇌의 학습 메커니즘을 그대로 설명하는 비유로 받아들이지 말자.



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 예측 → 오차 측정 → 변화 방향 계산 → 작은 수정.

WORKSHOP / 10 MIN

활동: 직접 경계 탐지기가 되어 보자.


코드 없이도 합성곱이 무엇을 계산하는지 확인할 수 있다.

WORKSHOP

① **2분** 오른쪽 5×5 이미지에서 왼쪽 위 3×3 패치를 선택한다.
필터와 같은 위치끼리 곱하고 모두 더한다.

② **4분** 창을 오른쪽으로 옮겨 첫 번째 출력 행의 세 값을
계산한다. 어느 위치의 반응이 가장 클지 먼저 예측하자.

③ **4분** 같은 계산을 아래 행에도 적용한다. 원본을 좌우 반전하면
결과의 부호와 위치가 어떻게 달라질지 설명한다.



padding = 0 · stride = 1 · bias = 0

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 정답 숫자보다, 어떤 밝기 차이를 계산했는지 말로 설명하는 것이 목표다.

WORKSHOP / 5 MIN

활동 해설: 반응에는 방향이 있다.

밝은 곳 자체가 아니라, 이 필터가 보는 좌우 차이가 응답을 만든다.

각 패치에서 오른쪽 열의 합에서 왼쪽 열의 합을 뺀다. 첫 번째와 두 번째 창은 3, 세 번째 창은 0이므로 모든 출력 행은 [3, 3, 0]이다.

같은 밝기의 영역에서는 양쪽 값이 상쇄된다. 반전된 이미지에서는 경계 방향이 바뀌어 음수 반응이 나타난다. ReLU를 붙이면 이 음수는 사라진다. 반대 방향을 찾는 필터도 필요할 수 있다.



padding = 0 · stride = 1 · bias = 0

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 좋은 특징 하나가 모든 패턴을 다 설명하지는 못한다.

함께 생각하기 반대 부호 필터와 원래 필터를 함께 쓰면 무엇을 구분할 수 있을까?

RECAP / EXPLAIN IT TO A FRIEND

이제 CNN을 다섯 문장으로.

용어를 외우는 대신, 한 단계가 다음 단계에 왜 필요한지 연결해 보자.

이미지는 위치를 가진 숫자 배열이다. 지역 필터는 주변 값들의 패턴을 계산한다.

같은 필터를 여러 위치에서 공유해 특징 맵을 만든다. 비선형 변환과 여러 층이 더 복잡하고 넓은 문맥의 조합을 가능하게 한다.

분류기는 표현에서 후보별 점수를 만들고, 손실과 역전파로 전체 가중치가 함께 조정된다.

01 숫자

02 지역 패턴

03 공유와 조합

04 범주 점수

05 학습

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember CNN의 핵심은 “물체 그림을 저장”하는 것이 아니라 “분류에 유용한 표현을 학습”하는 것이다.

함께 생각하기 출구 질문: 특징 맵은 클래스 확률인가? pooling은 정보를 모두 보존하는가? CNN은 뇌와 같은가?

FIELD NOTES / KEEP THIS PAGE

개념 사전: 이름보다 역할을 기억하기.

오늘의 용어를 입력·중간 표현·학습의 언어로 다시 정리한다.

필터 / kernel 작은 영역을 하나의 반응으로 바꾸는 학습 가능한 가중치 묶음.

특징 맵 한 필터의 위치별 반응을 모은 지도.

채널 같은 위치에서 서로 다른 값이나 특징을 담는 축.

수용 영역 특정 출력에 영향을 줄 수 있는 입력 범위.

가중치 공유 여러 위치에 같은 계산 기준을 적용하는 구조.

비선형성 여러 층의 조합이 단일 선형 계산을 넘어가도록 하는 요소.

logits 정규화 전의 클래스 점수.

손실 학습 목표에서 예측의 잘못을 수치화한 값.

gradient 파라미터 변화에 대한 손실의 국소 변화율.

Remember 다음 주: 모델이 맞았다는 사실만으로, 올바른 근거를 배웠다고 말할 수 있을까?

READING ROOM / WEEK 01

아이디어의 출처를 따라 읽기.

원문을 통해 생물학적 관찰과 공학적 구현 사이의 연결을 확인한다.

먼저 읽기 Hubel & Wiesel의 연구 대상과 수용 영역 개념을 확인한다. 관찰이 곧 인간 인지 전체의 모형을 뜻하지는 않는다.

이어 읽기 Neocognitron과 LeCun 등의 문서 인식 연구가 지역성과 계층적 계산을 어떻게 사용했는지 비교한다.

경계를 넓히기 시각적 패턴 완성에서 반복 계산을 다룬 연구를 읽고, 단순한 feed-forward CNN이 설명하지 못하는 부분을 질문한다.

01 / Hubel & Wiesel (1962) · 고양이 시각피질의 수용 영역

<https://pmc.ncbi.nlm.nih.gov/articles/PMC1359523/>

02 / Fukushima (1980) · Neocognitron

<https://pubmed.ncbi.nlm.nih.gov/7370364/>

03 / LeCun et al. (1998) · Gradient-Based Learning Applied to Document Recognition

<https://bottou.org/papers/lecun-98h>

04 / Tang et al. (2018) · Recurrent computations for visual pattern completion

<https://doi.org/10.1073/pnas.1719397115>

Remember 본문 도식과 계산 예제는 수업용으로 새로 작성했다. 도식의 막대·점수는 실제 논문 측정값이 아니다.