

02 / LEARNING & GENERALIZATION

잘 맞혔다고, 잘 본 것일까?

CNN이 무엇을 배웠는지 묻는 두 번째 시각 수업.

CNN ② · 단서, 지름길, 일반화

90분 · 비교, 개입, 설계, 토론

AIM DEEP LEARNING STUDY / 2026



SHAPE / TEXTURE / EVIDENCE

정답뿐 아니라, 정답에 도달한 근거를 살펴보기.

SESSION MAP / 90 MIN

이번 주의 질문은 “왜 맞았나?”

구조를 안다는 것에서 출발해, 학습과 평가를 설계하는 관점까지 확장한다.

01 단서 사람과 CNN이 같은 사진에 같은 답을 해도 같은 근거를 썼다고 할 수 있을까?

02 설계 데이터·증강·깊이·잔차 연결은 무엇을 바꾸며 어떤 한계가 있을까?

03 검증 새로운 조건에서도 통하는지 보려면 무엇을 고정하고 무엇을 바꿔야 할까?

00-05	지난주 구조 복원	5분
05-20	단서·지름길·데이터	15분
20-35	증강과 이동의 차이	15분
35-50	깊이·잔차·규제	15분
50-65	평가와 근거 확인	15분
65-80	데이터·시험지 설계 활동	15분
80-90	해설과 종합	10분

코딩 실습은 별도 선택 확장입니다. 이 시간표는 개념 수업만으로 90분을 구성합니다.

Remember 도입 5 + 단서·데이터 15 + 변환 15 + 학습 설계 15 + 평가 15 + 활동 15 + 종합 10 = 90분.


RETRIEVAL / 3 MIN

지난주 구조를 한 번에 복원하기.

처음 보는 사람에게 “CNN은 무엇을 하는가”를 설명한다면?

필터는 작은 패턴을 계산하고, 같은 필터가 여러 위치에서 공유된다. 여러 층은 그 반응들을 다시 조합한다.

분류 점수와 정답의 차이가 손실을 만들고, 가중치는 그 손실을 줄이는 방향으로 바뀐다. 그런데 어떤 단서로 손실을 줄일지가 모두 정해져 있는 것은 아니다.



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 학습 목표가 “맞히기”일 때, 우리가 원한 방식으로 맞힐지는 따로 확인해야 한다.

함께 생각하기 “컵을 알아봤다”와 “컵 라벨을 맞혔다” 사이에 어떤 차이가 있을까?

01 / SHAPE VS TEXTURE

형태와 무늬가 서로 다른 말을 한다면.

고양이 윤곽에 줄무늬를 입혔을 때 무엇이라고 부를까?

사람이 활용하는 단서와 모델이 활용하는 단서는 다를 수 있다. Geirhos 등의 특정 ImageNet 학습 CNN 실험에서는 질감에 크게 의존하는 현상이 관찰됐다.

이를 “모든 CNN은 형태를 못 본다”로 바꾸어 말하면 안 된다. 같은 구조도 데이터와 학습 조건에 따라 사용하는 단서가 달라질 수 있다. 오른쪽 그림은 원문 자극이 아닌 수업용 예시다.



윤곽 + 단색



같은 윤곽 + 다른 무늬

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 구조만으로 지각 방식이 완전히 결정되지 않는다. 데이터와 목표도 중요하다.

함께 생각하기 윤곽은 그대로 두고 무늬만 바꾸면, 어떤 비교를 할 수 있을까?

02 / SHORTCUT LEARNING

쉬운 단서가 좋은 단서와 같지는 않다.

컵을 배웠다고 생각했는데, 사실은 주황 배경을 배웠을 수도 있다.

학습 사진의 컵은 항상 주황 배경, 병은 항상 초록 배경에 있다면 색만 보아도 정답을 맞힐 수 있다. 배경과 라벨의 상관관계가 편리한 지름길이 된다.

새로운 배경에서는 이 규칙이 무너질 수 있다. 학습 데이터에서는 유효했던 규칙이 사용 환경에서도 유효한지 묻는 것이 일반화 평가의 핵심이다.



라벨과 배경이 묶임

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 학습 데이터에서 잘 작동하는 규칙이 우리가 원한 개념과 일치하는지 확인한다.

03 / DATA AS AN EXPERIMENT

좋은 데이터는 변화를 교차시킨다.

컵은 여러 배경에, 같은 배경에는 여러 종류의 물체를 배치한다.

모델이 배경 하나만으로 라벨을 결정하기 어렵게 예시를 구성한다. 물체·배경·조명·촬영 기기 같은 요인이 한 범주에만 묶여 있지 않은지 확인하자.

모든 변화를 수집할 수는 없다. 실제로 사용할 환경에서 중요한 변화가 무엇인지 먼저 정하고, 표본 수뿐 아니라 **조건의 다양성**을 점검한다.



같은 물체를 서로 다른 배경에

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 데이터를 많이 모으는 일과 필요한 경우를 빠짐없이 모으는 일은 다르다.

함께 생각하기 물체와 배경이 섞이지 않은 데이터에 증강만 추가하면 충분할까?


04 / TRAIN · VALIDATION · TEST

연습 문제와 마지막 시험을 나누는 이유.

모델을 고르는 데 이미 사용한 문제는 새로운 능력을 공정하게 시험하기 어렵다.

train은 가중치를 학습하는 데, validation은 구조나 설정을 고르는 데 사용한다. test는 선택을 끝낸 뒤 결과를 평가하는 데 남겨 둔다.

서로 다른 파일이라도 같은 촬영 연속 장면이나 같은 원본의 변형이면 사실상 정보가 겹칠 수 있다. 실제 사용 목적에 따라 사람·물체·장소·시간 단위 분할이 필요할 수 있다.



공유 원본·물체·장면이 split 경계를 넘는지 확인

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 파일 이름이 다르다는 것보다, 평가에 필요한 독립성이 있는지가 중요하다.

함께 생각하기 한 컵을 연속 촬영한 100장을 무작위로 나누면 어떤 능력을 평가하게 될까?

05 / AUGMENTATION

증강은 모델에게 보여 주는 변화다.

“이 정도로 달라져도 답은 같다”는 가정을 새로운 예시로 표현한다.

crop, 색 변화, 좌우 반전은 입력의 모습을 바꾸면서 라벨을 유지하는 경우에 쓴다. 모델이 우연한 위치나 밝기에 덜 의존하도록 유도할 수 있다.

하지만 crop이 물체를 완전히 지우거나 회전이 숫자의 의미를 바꾸면 잘못된 학습 예시가 된다. 변환 이름보다 **라벨을 보존하는가**를 먼저 판단하자.



변환 관찰 도구입니다. 모델을 실행하거나 분류 결과를 측정하지 않습니다.

Remember 증강은 상식의 자동 적용이 아니라, 데이터에 대한 가정이다.

함께 생각하기 웹에서 변환을 바꾸고, 어떤 변환은 컵 분류에 괜찮지만 글자 인식에는 위험한지 말해 보자.


06 / EQUIVARIANCE ≠ INVARIANCE

움직임을 따라가는 것과 무시하는 것.


두 성질은 비슷하게 들리지만 출력에 요구하는 것이 다르다.

입력이 움직였을 때 특징 맵도 함께 움직이면 **등변성**이라고 한다.
반면 이동 전후의 최종 분류가 같기를 바라는 것은 **불변성**에
가깝다.

같은 필터를 공유하는 stride 1 합성곱에는 이동을 따라가는
구조가 있다. 그러나 경계·padding·stride·요약 때문에 실제
네트워크 전체의 완전한 이동 불변성은 보장되지 않는다.



위: 등변성 / 아래: 원하는 분류 불변성



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 입력 이동 → 특징 이동 / 입력 이동 → 같은 분류. 무엇을 비교하는지 먼저 정하자.

함께 생각하기 특징 맵이 달라졌다는 이유만으로 분류 모델이 실패했다고 말할 수 있을까?

07 / DOWNSAMPLING & LOST DETAIL

작은 이동이 요약 결과를 바꿀 수도 있다.

눈금 사이로 빠지는 가는 선을 상상해 보자.

stride를 크게 하거나 해상도를 빠르게 줄이면 작은 패턴이 어느 위치에 놓였는지에 따라 남거나 사라질 수 있다. 표본을 성기게 읽는 과정에서 차이가 확대되기도 한다.

pooling은 계산량을 줄이고 일부 위치 차이를 요약하지만, 작은 물체의 정보까지 버릴 수 있다. 해상도와 비용의 절충을 데이터에 맞춰 판단해야 한다.



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember “조금 움직여도 괜찮을 것”이라는 기대는 실제 입력 변형으로 검증한다.


08 / CAPACITY

채널을 늘리고 층을 깊게 하면.

더 많은 질문을 던지거나, 질문의 결과를 더 여러 번 조합할 수 있다.

채널 수를 늘리는 것은 한 단계에서 만들 수 있는 특징 지도의 수를 늘리는 일이다. 깊이를 늘리는 것은 표현을 변환하고 조합하는 단계를 추가하는 일이다.

더 큰 모델이 더 좋은 답을 배우려면 충분한 데이터와 학습이 필요하다. 계산량·메모리·과적합 가능성도 함께 늘 수 있어 크기 하나만으로 선택할 수는 없다.



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 모델 크기는 가능성을 늘린다. 좋은 일반화를 자동으로 보장하지는 않는다.

함께 생각하기 작은 데이터에서 성능이 낮을 때, 가장 먼저 모델을 크게 만드는 것이 합리적일까?

09 / EXPRESSION & OPTIMIZATION

더 깊다는 것의 두 얼굴.

만들 수 있는 함수가 풍부해지는 것과, 학습으로 좋은 함수를 찾는 것은 다른 문제다.

층을 늘리면 더 복잡한 표현을 만들 여지가 있지만, 가중치를 잘 조정하는 일도 어려워질 수 있다. 훈련 손실 자체가 개선되지 않는 문제와 훈련만 잘되는 과적합을 구분하자.

각 깊은 층이 반드시 사람이 아는 물체 부분 하나에 해당하는 것도 아니다. 계층적 계산의 장점과 내부 표현의 의미 해석은 서로 다른 질문이다.



더 많은 변환 단계 $\neq$ 자동으로 더 좋은 학습

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 표현력, 최적화, 일반화는 함께 연결되지만 같은 단어가 아니다.

함께 생각하기 train도 나쁜 모델과 train은 좋은데 validation만 나쁜 모델은 같은 처방이 필요할까?


10 / RESIDUAL CONNECTION

처음부터 다시 쓰지 말고, 수정량을 더하자.

입력 x 를 남겨 두고 블록이 계산한 $F(x)$ 를 더한다.

잔차 연결은 $y = x + F(x)$ 로 표현한다. 블록이 큰 변화를 만들지 않아도 입력이 다음 단계로 전달될 경로가 생긴다.

이 연결은 깊은 네트워크를 학습하는 데 도움이 될 수 있다. 두 경로를 더하려면 크기가 맞아야 하며, 다르면 projection 같은 변환을 사용한다. 잔차 연결 하나로 모든 학습 문제가 해결되지는 않는다.



$$y = x + F(x)$$

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 입력을 전달하는 경로와 입력을 수정하는 경로를 함께 둔다.


11 / NORMALIZATION

값의 크기도 학습 환경의 일부다.

활성화의 규모가 지나치게 흔들리면 학습 설정에 민감해질 수 있다.

BatchNorm은 채널별 활성화를 배치·공간 통계로 정규화한 뒤 학습 가능한 크기와 이동을 적용한다. 값들을 무조건 같은 상수로 만드는 연산은 아니다.

학습과 평가에서는 사용하는 통계가 다르다. 입력 픽셀의 Normalize와 중간 활성화의 BatchNorm은 위치와 역할이 다르며, 인간 시각의 적응을 그대로 재현한다고 설명할 필요도 없다.



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 입력 전처리와 네트워크 내부의 정규화를 구분해 이름 붙인다.


12 / REGULARIZATION

한 단서에만 기대지 않게 유도하기.

훈련 예시를 잘 맞추는 방법은 여러 가지다. 어떤 해를 선호할지 추가 조건을 줄 수 있다.

Dropout은 학습 중 일부 활성화를 무작위로 비워 특정 조합에 과도하게 의존하는 것을 줄이려는 기법이다. 평가할 때는 그 무작위 제거를 끈다.

weight decay는 큰 가중치를 억제하는 방향의 규제를 준다. 두 방법 모두 강도를 과하게 높이면 학습을 방해할 수 있다. 데이터 부족이나 잘못된 라벨을 자동으로 고쳐 주지는 않는다.



학습 중 무작위로 일부 활성화를 비움

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 규제는 학습을 돕는 선택지이며, 성능을 올리는 만능 장식이 아니다.


13 / READING LEARNING CURVES

학습 곡선은 진단을 시작하는 그림이다.

어디가 나쁜지 먼저 구분하고, 원인은 추가 실험으로 좁힌다.

train과 validation 손실이 모두 높으면 학습 부족, 모델 제약, 데이터 문제 등을 의심할 수 있다. train만 계속 좋아지는데 validation이 나빠지면 과적합 가능성을 살펴본다.

곡선 모양 하나로 원인이 확정되지는 않는다. train에는 증강·Dropout이 적용되지만 validation에는 적용되지 않는 등 측정 조건도 다를 수 있다.



설명용 합성 곡선 / 실제 학습 기록 아님

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 관찰 → 가능한 원인 → 한 변수 변경 → 재측정. 오른쪽 곡선은 설명용 합성 값이다.

14 / ACCURACY VS LOSS

정확도가 같아도 손실은 다를 수 있다.

정답 여부와 정답에 배정한 확률은 서로 다른 정보를 요약한다.

정답이 컵일 때 $[0.6, 0.3, 0.1]$ 과 $[0.9, 0.05, 0.05]$ 는 모두 컵을 고른다. accuracy는 같지만 정답 확률이 다른 만큼 cross entropy도 다르다.

반대로 아주 확신하며 틀린 예측은 큰 손실을 줄 수 있다. 지표 하나가 모든 목적을 대변하지 않으므로, 어떤 오류가 중요한지에 맞춰 함께 읽는다.

예측 A



정답: 컵 · $CE \approx 0.511$

예측 B



정답: 컵 · $CE \approx 0.105$

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember accuracy는 맞힌 비율, CE는 정답 분포에 대한 예측의 적합도를 반영한다.

함께 생각하기 두 예측의 CE $-\log(0.6)$, $-\log(0.9)$ 를 비교해 보자.

15 / CONFUSION MATRIX

어떤 종류를 어떻게 틀리는가?

전체 정확도를 클래스별 실패의 지도로 풀어 본다.

행을 실제 정답, 열을 예측으로 두면 대각선은 맞힌 개수다. 한 행을 보면 그 클래스가 어떤 다른 클래스로 오인되었는지 알 수 있다.

클래스별 recall은 그 행의 정답 개수를 행 전체로 나눈 값이다. 실제 표본이 적거나 아예 없는 클래스에서는 수치의 의미를 조심해서 읽어야 한다.

	컵	병	그릇	
컵	8	1	1	8/10
병	2	6	2	6/10
그릇	0	3	7	7/10

행 = 실제 정답 / 열 = 예측

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 좋은 평가에는 전체 점수뿐 아니라 실패하는 범주와 사례가 들어간다.

함께 생각하기 오른쪽 예시에서 병의 recall은 얼마인가? 컵으로 예측한 것 중 진짜 컵의 비율은?

16 / DISTRIBUTION SHIFT

새로운 장소에서도 같은 규칙이 통할까?

평가 데이터가 학습 데이터와 비슷하다는 사실도 하나의 조건이다.

스튜디오에서 촬영한 물체로 학습한 모델을 어두운 휴대폰 사진에 적용하면 입력의 분포가 달라질 수 있다. 위치·조명·센서·배경의 조합이 바뀐다.

모든 조건을 한 번에 “새 데이터”로 묶기보다 중요한 변화별로 나누어 성능을 살펴보자. 전체 평균은 특정 조건에서의 큰 실패를 가릴 수 있다.



밝은 촬영실



어두운 다른 장소

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 일반화는 어느 분포에서 어느 분포로 옮겨 가는지를 포함한 질문이다.

17 / INTERPRETATION

빨간 영역이 곧 이유의 전부일까?

시각화는 질문을 만들어 주지만, 모든 인과적 설명을 대신하지는 못한다.

특징 맵이나 Grad-CAM 같은 시각화는 모델 반응과 관련된 위치를 관찰하는 데 도움이 된다. 그러나 색이 강한 영역 하나가 예측의 유일한 원인이라고 단정할 수는 없다.

시각화 방식과 선택한 층에 따라 그림이 달라질 수 있다. 입력을 바꾸었을 때 실제 출력이 어떻게 변하는지 등 다른 근거와 함께 살펴보자.



가상 heatmap / 특정 모델의 Grad-CAM 결과 아님

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 보기 좋은 지도와 충분히 검증된 설명을 구분한다.

18 / INTERVENTION

근거를 묻고 싶다면, 입력을 바꿔 보자.

물체를 그대로 두고 배경만 바꾸거나, 배경을 그대로 두고 물체를 가린다.

모델이 물체를 보는지 배경을 보는지 의심된다면 그 요인을 바꾸어 비교할 수 있다. 같은 물체가 다른 배경에서도 같은 답을 얻는지 확인하자.

다만 검은 사각형으로 가리는 것 자체가 낯선 입력을 만든다. 예측 변화가 어떤 정보 제거 때문인지, 새로 생긴 왜곡 때문인지도 생각해야 한다.



원본

물체 가림

배경 변경

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 한 번의 그림으로 증명하기보다, 의심한 규칙을 겨냥한 비교를 설계한다.

함께 생각하기 원본, 배경 교체, 물체 가림 세 조건이 각각 어떤 가설을 시험하는가?


19 / CONTROLLED COMPARISON

한 가지만 바꿨다고 말할 수 있는가?

잔차 블록을 넣으며 층 수도 늘었다면, 무엇 때문에 성능이 바뀌었을까?

같은 분할, 같은 모델 body, 같은 초기값과 학습 예산에서 skip 연결만 켜고 끄면 연결 효과를 더 직접적으로 비교할 수 있다.

반면 다른 구조와 다른 파라미터 수를 비교했다면 그 사실을 결과에 적어야 한다. 하나의 seed에서 작은 차이가 났다면 반복 실험으로 변동을 확인할 필요가 있다.



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 주장하는 원인과 실제로 바꾼 변수가 일치하는지 확인한다.

함께 생각하기 데이터 수, epoch, batch가 달라지면 “같은 학습 예산”이라는 말은 어떻게 달라질까?

WORKSHOP / 10 MIN

활동: 컵 분류기의 시험지를 설계하자.

아래 가상의 데이터로 학습한 모델을 믿기 전에 어떤 시험이 필요할까?

주어진 상황 컵 사진 100장은 모두 책상 위, 병 사진 100장은 모두 선반 위다. 모든 사진은 같은 휴대폰으로 낮에 찍었다.

팀 과제 ① 가능한 지름길 두 가지 ② 개선할 수집 조합 ③ train/val/test 분할 단위 ④ 새 시험 조건 두 가지를 정한다.

제약 추가 촬영은 40장만 가능하다. 어떤 40장을 고를지 근거를 포함해 설명한다.



컵 / 책상 / 낮



병 / 선반 / 낮

예산: 추가 사진 40장

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 많은 사진보다 어떤 비교를 가능하게 하는 사진인지부터 생각한다.

WORKSHOP / 5 MIN

활동 해설: 숫자보다 설계의 근거.

한 가지 가능한 설계안을 서로 비판하며 보완한다.

컵-선반 10장, 병-책상 10장을 추가해 배경과 라벨의 결합을 일부 끊을 수 있다. 나머지 20장은 목표 환경에 필요한 다른 조명이나 기기 조건에 배정할 수 있다.

같은 물체의 연속 사진이 split 사이에 섞이지 않게 나눈다. 배경 교차 조건과 조명 변화 조건을 따로 평가해, 어떤 변화에서 실패하는지 구분한다.

이것은 유일한 정답이 아니다. 목표가 새로운 물체 인스턴스인지 같은 물체의 새로운 사진인지에 따라 분할과 수집 전략이 달라진다.



컵 / 책상 / 낮



병 / 선반 / 낮

예산: 추가 사진 40장

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 추가 데이터가 어떤 가설을 더 잘 시험하게 하는지 설명하면 좋은 설계다.

RESEARCH NOTE / 5 MIN

좋은 결과 보고서는 네 부분으로 쓴다.

성능을 자랑하는 문장에서, 검토 가능한 주장으로 바꾼다.

질문 배경을 다양하게 수집하면 새 배경에서 오류가 줄어드는가?

방법과 증거 고정한 조건, 변경한 데이터, 평가 표본 수와 클래스별 결과를 표·그림으로 남긴다.

한계와 다음 실험 한 seed, 작은 표본, 제한된 기기라는 범위를 적고 다음에 분리해 볼 변수 하나를 제안한다.

01 **질문**

02 **비교 방법**

03 **관측 결과**

04 **한계**

05 **다음 실험**

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 관측하지 않은 수치를 채우지 않는다. 개선되지 않은 실험도 잘 설계되었다면 의미가 있다.


RECAP / THE BRIDGE AND THE GAP

인간에서 출발해, 차이까지 이해하기.

비슷한 기능을 수행한다는 것과 같은 방식으로 작동한다는 것은 다르다.

인간 시각의 지역적·계층적 처리에 대한 연구는 CNN을 이해하는 중요한 출발점이다. CNN은 지역 연결, 가중치 공유, 학습 가능한 여러 층으로 이미지를 계산한다.

그러나 사용하는 단서와 학습 경험, 반복 처리, 맥락의 역할은 인간과 같다고 보장되지 않는다. 모델의 성공과 실패를 데이터와 실험을 통해 살펴봐야 한다.



영감과 공통점 / 차이와 검증

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember “어떻게 흉내 냈나”를 배운 뒤에는 “어디까지 닮았나”를 검증해야 한다.

함께 생각하기 출구 질문: 증강이 항상 좋은가? residual은 정확도를 보장하는가? 높은 accuracy면 올바른 근거를 썼는가?

NEXT / THEORY INTO AN EXPERIMENT

그다음에 코드를 열어야 하는 이유.

이제 구현의 각 줄을 설계 선택으로 읽을 준비가 되었다.

Conv와 채널 어떤 패턴을 어느 범위에서
계산하는가?

pooling과 stride 무엇을 요약하며 어떤
세부를 버리는가?

데이터와 증강 어떤 변화는 무시해도 된다고
가정하는가?

loss와 optimizer 무엇을 잘하도록
가중치를 조정하는가?

검증과 시각화 어떤 조건의 성공을 확인했고,
무엇은 아직 모르는가?

Remember 기존 practice.ipynb와 자율 과제는 이 질문을 직접 시험하는 선택 실습으로 활용한다.

READING ROOM / WEEK 02

성공 사례와 한계를 함께 읽기.

기법의 이름보다 연구가 비교한 조건과 근거를 먼저 살펴본다.

표현과 지름길 Shape/texture bias와 Shortcut Learning을 읽으며 모델·데이터·평가 조건의 범위를 확인한다.

학습 구조 Residual, BatchNorm, Dropout이 각각 어떤 문제를 겨냥하는지 비교한다.

해석 Grad-CAM의 그림이 무엇을 계산하며 무엇을 직접 증명하지는 않는지 토론한다.

01 / Geirhos et al. (2019) · Shape / texture bias<https://arxiv.org/abs/1811.12231>**02 / Geirhos et al. (2020) · Shortcut Learning**<https://arxiv.org/abs/2004.07780>**03 / He et al. (2015/2016) · Deep Residual Learning**<https://arxiv.org/abs/1512.03385>**04 / Ioffe & Szegedy (2015) · Batch Normalization**<https://arxiv.org/abs/1502.03167>**05 / Srivastava et al. (2014) · Dropout**<https://jmlr.org/papers/v15/srivastava14a.html>**06 / Selvaraju et al. (2017) · Grad-CAM**<https://arxiv.org/abs/1610.02391>

Remember 이 자료의 예시 수치·합성 곡선·가상 분류기는 사고 실험이다. 실행된 벤치마크 결과와 구분한다.