

논문 읽기 · CNN

AlexNet (2012)

ImageNet Classification with Deep Convolutional Neural Networks

ImageNet Classification with Deep Convolutional Neural Networks

논문 제목 · 원문 1쪽 ↗

Alex Krizhevsky · Ilya Sutskever · Geoffrey E. Hinton

Advances in Neural Information Processing Systems 25

CNN 복습

필터 → 특징 → 분류

논문 분석

문제 → 구조 → 학습

결과 해석

실험 → Discussion → 기록

90분 · 복습 6페이지 + 논문 분석 15페이지

CNN 복습 · 1 / 6

이미지 분류의 입력과 출력

이미지 한 장을 받아, 정해진 클래스마다 점수를 계산한다.

이미지	CNN	분류 점수
높이 × 너비 × 채널	학습한 특징으로 변환	클래스 수만큼 출력
	MNIST	AlexNet의 분류 과제
입력	28 × 28 × 1 · 흑백 숫자	RGB 자연 이미지
출력	숫자 0-9 · 10개 점수	ILSVRC · 1,000개 클래스 점수
정답	이미지당 클래스 라벨	이미지당 클래스 라벨


이미지 분류는 “어떤 클래스인가”를 예측한다. 물체의 위치를 찾는 객체 검출과는 출력이 다르다.

CNN 복습 · 2 / 6

합성곱: 같은 필터를 여러 위치에 적용

필터는 사람이 정한 체크리스트가 아니라, 학습으로 값이 바뀌는 가중치 배열이다.

작은 영역을 보고, 같은 질문을 옮긴다



입력의 3 × 3 영역

수업용 손계산 · 실제 학습에서는 필터 값 자체가 바뀐다.

수업용 재구성 · 논문 원문 그림과 구별

국소 연결

입력 전체가 아닌 작은 영역을 한 번에 본다.

가중치 공유

같은 필터를 이동하며 사용한다. 위치마다 새 필터를 만들지 않는다.

특징 맵

각 위치에서 계산한 반응값을 공간에 맞춰 모은 결과.

반응값 = $\Sigma(\text{입력값} \times \text{필터 가중치}) + \text{편향}$


그림은 수업용 손계산 예제. 실제 필터의 값은 정답과 예측의 차이를 줄이는 방향으로 학습한다.

CNN 복습 · 3 / 6

채널과 깊이: 여러 반응을 조합

필터 하나가 출력 채널 하나를 만들고, 다음 층은 그 채널들을 함께 읽는다.

RGB는 입력 채널, 필터 개수는 출력 채널



입력: 3개 채널

출력: 여러 특징 맵

하나의 $11 \times 11 \times 3$ 필터 → 한 출력 채널

수업용 재구성 · 논문 원문 그림과 구별

채널

첫 입력은 R·G·B. 이후 채널은 학습한 필터에 대한 반응이다.

깊이

뒤쪽 층은 앞쪽 층의 반응을 조합한다.

수용 영역

한 반응에 영향을 주는 원본 이미지의 범위. 층을 거치며 넓어질 수 있다.

사람이 획과 모양의 관계를 보는 것에 비유할 수 있다. 다만 특정 채널이 반드시 “눈”이나 “귀”를 뜻하는 것은 아니다.

CNN 복습 · 4 / 6

ReLU와 pooling의 역할

ReLU는 값에 비선형 규칙을 적용하고, pooling은 주변 반응을 요약한다.

$$\text{ReLU}(x) = \max(0, x)$$


$-2 \rightarrow 0 \cdot 0 \rightarrow 0 \cdot 3 \rightarrow 3$

음수는 0으로, 양수는 그대로 통과시킨다. 여러 층이 복잡한 관계를 학습하도록 비선형성을 넣는다.

Stride는 창을 옮기는 간격.

Padding은 가장자리에 더하는 값.

3 × 3 창을 2칸씩 이동: 영역이 겹친다



수업용 예제 · 같은 채널 안에서 주변 반응을 요약

수업용 재구성 · 논문 원문 그림과 구별

Max pooling은 각 채널 안에서 최댓값을 남긴다. 위치 정보를 일부 줄이지만 모든 이동에 같은 출력을 보장하지는 않는다.

CNN 복습 · 5 / 6

분류와 학습: 정답 확률을 높이는 과정

예측에 사용한 필터와 분류기의 가중치를 같은 손실로 함께 학습한다.

CNN + 분류기

클래스별 점수 z

Softmax

점수 $\rightarrow$ 확률 p

손실

정답 확률이 작으면 큰 값

$$p(k | x) = \exp(z_k) / \sum_j \exp(z_j) \quad L = -\log p(y | x)$$

수업용 표기 · y 는 정답 클래스. AlexNet § 3.5의 정답 로그확률 최대화를 손실 최소화로 쓴 형태.

순전파에서 예측과 손실을 계산한다. 역전파로 가중치별 기울기를 구하고, 옵티마이저로 가중치를 갱신한다.

정답 확률 0.8과 0.2 중에서는 0.2일 때 손실이 더 크다. 추론에서는 입력으로 예측만 계산한다.

CNN 복습 · 6 / 6

일반화: 처음 보는 이미지에서도 맞히기

훈련 성능만으로는 모델이 새로운 이미지에 잘 적응되는지 알 수 없다.

데이터 구분	역할	주의할 점
Train · 훈련	가중치 갱신	이 데이터에서만 잘 맞힐 수 있다
Validation · 검증	모델·학습 설정 선택	설정 선택에 사용했다면 최종 시험과 구분
Test · 시험	최종 성능 평가	시험 결과로 설정을 반복 조정하지 않는다

과적합

훈련 데이터에 지나치게 맞춰져, 새로운 데이터에서는 성능이 떨어지는 현상.

대응 방법

데이터 증강, dropout, weight decay 등. 효과는 검증·시험 조건과 함께 확인한다.

원문 읽기 · 문제와 제안

Abstract · Introduction

현실의 이미지에는 변형이 많다. 큰 데이터와 큰 모델을 어떻게 함께 쓸 것인가?

원문의 논리	이 논문에서 읽을 내용
기존 문제	작은 데이터만으로는 현실 이미지의 다양한 모양·배경·조명을 다루기 어렵다.
필요한 조건	많은 라벨 데이터, 표현력이 큰 모델, 과적합 억제, 감당 가능한 학습 시간.
제안	깊은 CNN을 GPU로 학습하고 ReLU·증강·dropout 등을 함께 사용한다.
확인할 근거	구조는 Figure 2, 성능은 Tables 1-2, 구성 요소의 근거는 § § 3-4.

초록의 성능 수치는 결론의 예고다. 단일 모델인지, 어떤 데이터와 지표인지 실험 절에서 다시 확인한다.

§ 2 · § 3.5

The Dataset · 문제 정의

RGB 이미지 한 장을 1,000개 클래스 중 하나로 분류한다.

조건	논문의 설정
데이터	ImageNet의 ILSVRC 부분집합
규모	훈련 약 120만 · 검증 5만 · 시험 15만 장
입력 처리	256 × 256으로 정리 후 224 × 224 crop
학습 목표	정답 클래스의 로그확률을 높인다

Top-1 error

가장 높은 점수의 클래스가 정답과 다른 비율.

Top-5 error

점수가 높은 5개 클래스 안에 정답이 없는 비율.

비교 조건

ILSVRC-2010과 2012, 검증과 시험 결과를 나눠 읽는다.

독립된 Problem statement 절은 없다. § § 1·2·3.5에서 입력·출력·목표를 모아 재구성한 것이다.

§ 3.5 · Figure 2

The Architecture

가중치가 있는 8개 층: 합성곱 5개 + 완전연결 3개.




Figure 2 · 두 GPU에 나누어 배치한 하나의 네트워크 · 원문 5쪽 ↗

Conv 1-5

국소 특징과 그 조합

FC 6-8

4,096 → 4,096 → 1,000

Softmax

1,000개 클래스의 확률

ReLU·pooling·정규화는 “8개 학습 층”과 별도로 읽는다. 그림의 위·아래는 GPU 분할이며, 독립 모델의 앙상블이 아니다.

§ 6.1 · Figure 3

첫 합성곱 층은 무엇을 학습했나

96개의 $11 \times 11 \times 3$ 필터를 학습한 뒤 시각화한 결과다.




Figure 3 · 첫 층의 학습된 필터 · 원문 6쪽 ↗

보이는 것

서로 다른 방향·주파수의 패턴과 색 반응이 나타난다.

그림의 대상

입력 이미지도, 특징 맵도 아니다. 학습된 필터 가중치다.

채널과 연결

필터 하나는 RGB 3개 채널을 함께 읽고, 한 출력 채널을 만든다.

위·아래 48개씩은 서로 다른 GPU에 배치된 필터다. 초기 층 그림만으로 모든 층의 의미를 설명할 수는 없다.

§ 3.1 · Figure 1

ReLU: 학습 속도의 근거

양수 영역에서 포화되지 않는 활성화가 학습 진행에 어떤 차이를 만드는가?




Figure 1 · 훈련 오류율과 epoch · 원문 3쪽 ↗

실험 설정

CIFAR-10 · 4층 CNN · ReLU(실선)와 tanh(점선).

관찰

훈련 오류율 25%에 도달하는 epoch가 ReLU에서 약 6배 적다.

해석 범위

ImageNet 최종 정확도 비교가 아니다. 학습률은 각각 선택했다.

$$f(x) = \max(0, x)$$

개념 → 수식 → 그래프 순서로 확인. “항상 벽시계 시간 6배 단축”으로 일반화하지 않는다.

§ 3.3 · § 3.4

LRN과 overlapping pooling

LRN은 채널 간 반응을 조절하고, pooling은 같은 채널의 주변 위치를 요약한다.


$$b_{x,y}^i = a_{x,y}^i / \left(k + \alpha \sum_{j=\max(0,i-n/2)}^{\min(N-1,i+n/2)} (a_{x,y}^j)^2 \right)^\beta$$

§ 3.3 · LRN 원문 수식 · 원문 4쪽 ↗

LRN

같은 위치에서 인접한 채널들의 반응 제곱합으로 나눈다. 주변 반응이 클수록 출력이 줄어드는 형태다.

3 × 3 창을 2칸씩 이동: 영역이 겹친다



수업용 예제 · 같은 채널 안에서 주변 반응을 요약

수업용 재구성 · 논문 원문 그림과 구별

Overlapping max pooling

3 × 3 창을 stride 2로 이동한다. 이웃한 창이 일부 영역을 공유한다.

LRN은 첫째·둘째 합성곱 층의 ReLU 뒤에 적용한다. 배치 평균·분산을 사용하는 BatchNorm과 다른 연산이다.

§ 4 · Data augmentation / Dropout

Reducing Overfitting

약 6천만 개의 파라미터를 가진 모델은 120만 장으로도 과적합할 수 있었다.

방법	논문의 설정	목적
공간 증강	256 × 256에서 무작위 224 × 224 crop + 좌우 반전	위치·방향 변화에 대응
색 증강	RGB 값의 주성분을 이용한 색 변화	조명·색 변화에 대응
Dropout	첫 두 FC 층의 은닉 출력을 확률 0.5로 0 처리	특정 은닉 단위 조합에 대한 의존 완화

학습과 시험을 구분한다. 학습에서는 무작위 crop을 사용한다. 시험에서는 5개 위치와 그 좌우 반전, 총 10개 crop의 예측 확률을 평균한다.

증강은 라벨 의미를 보존한다는 가정이 필요하다. Dropout은 학습 중 사용하고, 평가에서는 모든 은닉 단위를 사용한다.

§ 5 · 학습 조건

Details of Learning

구조만 같다고 같은 결과가 나오는 것은 아니다.

항목	논문의 설정	읽을 때 확인할 점
최적화	SGD · batch 128 · momentum 0.9	가중치를 어떻게 갱신했는가
규제	Weight decay 0.0005	손실과 함께 어떤 제약을 두었는가
학습률	0.01에서 시작, 검증 성능 정체 시 10분의 1	시험 데이터가 아닌 검증 성능으로 조절
학습량	약 90 epochs	데이터를 몇 번 반복해 보았는가
계산 자원	GTX 580 3GB 2개 · 약 5-6일	당시 메모리와 시간이 구조 선택을 제한

SGD·momentum·weight decay의 세부 식보다 각 설정의 역할을 먼저 읽는다. 재현 단계에서는 초기화와 전처리까지 확인한다.

§ 6 · Table 1

ILSVRC-2010: 이전 방법과의 비교

같은 시험 지표에서 제안한 CNN의 오류율을 비교한다.

Model	Top-1	Top-5
<i>Sparse coding [2]</i>	47.1%	28.2%
<i>SIFT + FVs [24]</i>	45.7%	25.7%
CNN	37.5%	17.0%

Table 1 · ILSVRC-2010 시험 오류율 · 원문 7쪽 ↗

Top-5 시험 오류율

SIFT + Fisher Vectors 25.7% → CNN 17.0%.

차이의 크기

8.7%p 감소. 상대 감소율로 계산하면 약 33.9%.

이 표는 최종 시스템의 성능 비교다. 개선분 전체를 ReLU나 dropout 한 가지의 효과라고 해석할 수는 없다.

§ 6 · Table 2

ILSVRC-2012: 단일 모델과 앙상블

행의 모델 조건과 열의 validation / test 구분을 함께 읽는다.

Model	Top-1 (val)	Top-5 (val)	Top-5 (test)
<i>SIFT + FVs [7]</i>	—	—	26.2%
1 CNN	40.7%	18.2%	—
5 CNNs	38.1%	16.4%	16.4%
1 CNN*	39.0%	16.6%	—
7 CNNs*	36.7%	15.4%	15.3%

Table 2 · ILSVRC-2012 오류율 · 원문 7쪽 ↗

1 CNN

Top-5 검증 **18.2%**. 시험값은 이 행에 없다.

7 CNNs*

Top-5 시험 **15.3%**. 여러 모델의 예측을 평균했다.

*의 의미

추가 ImageNet 데이터로 지도 사전학습한 모델을 포함한다.

7개는 일반 모델 5개 + 추가 사전학습 모델 2개다. 18.2% → 15.3%를 앙상블만의 효과로 계산하면 평가 집합과 학습 조건까지 섞인다.

§ 3-4 · 구성 요소 비교

각 구성 요소는 얼마나 기여했나

최종 점수와 별개로, 무엇을 바꿔 비교했는지 본문에서 찾는다.

비교	논문이 보고한 변화	해석할 때의 조건
LRN 사용	Top-1 / Top-5 오류 1.4 / 1.2%p 감소	LRN 유무 비교 · § 3.3
겹치는 pooling	0.4 / 0.3%p 감소	3×3 vs 2×2 , stride 2 · § 3.4
두 GPU의 큰 모델	1.7 / 1.2%p 감소	한 GPU의 더 좁은 모델과 비교 · § 3.2
중간 합성곱 층 제거	Top-1 성능 약 2%p 손실	깊이를 줄인 모델의 관찰 · § 7

각 숫자를 더해 전체 성능 향상을 설명할 수는 없다. 구성 요소는 서로 영향을 주며, GPU 비교는 모델 크기도 함께 달라진다.

확장 질문: 데이터·학습 예산을 고정하고 한 요소씩 바꾸면 같은 경향이 나오는가?

§ 6.1 · Figure 4 왼쪽

예측 사례: 무엇을 맞히고 틀렸나

원문이 고른 8개 시험 이미지의 상위 5개 예측을 살펴본다.




Figure 4 왼쪽 · Top-5 예측 · 원문 8쪽 ↗

읽는 순서

이미지 → 후보 클래스 → 확률 → 정답 표시.

관찰

물체가 중심에 없거나 장면에 여러 의미가 있을 때의 예측을 확인한다.

주의

그럴듯한 답과 데이터셋의 정답은 다를 수 있다. 8개 사례로 오류 유형의 빈도를 알 수는 없다.

§ 6.1 · Figure 4 오른쪽

은닉 표현: 어떤 이미지가 가까운가

픽셀 대신 마지막 은닉층의 4,096차원 벡터로 거리를 계산한다.




Figure 4 오른쪽 · 시험 이미지와 가까운 훈련 이미지 6개 · 원문 8쪽 ↗

첫 열은 시험 이미지.

나머지 열은 은닉 표현의 유클리드 거리가 가까운 훈련 이미지.

자세와 배경이 달라도 비슷한 물체가 가까울 수 있다. 분류를 위해 학습한 표현의 성질을 살펴보는 분석이다.

이웃 검색은 결과를 이해하기 위한 분석이다. AlexNet의 기본 분류 절차가 최근접 이웃 검색이라는 뜻은 아니다.

§ 7 · 주장의 범위와 남은 문제

Discussion

큰 깊은 CNN을 대규모 이미지 분류에 적용했을 때 얻은 성능 개선을 정리한다.

저자가 강조하는 결과

깊이가 중요했고, 중간 합성곱 층을 줄이면 성능이 나빠졌다.

계산 자원의 제약

모델 크기는 GPU 메모리와 감당 가능한 학습 시간의 영향을 받았다.

후속 방향

더 큰 모델과 데이터, 비디오의 시간 구조를 활용하는 학습.

이 논문에서 확인한 범위

해당 ImageNet 분류 설정에서 구조와 학습 기법을 함께 사용한 결과.

추가 검증이 필요한 것

새 도메인에서의 일반화, 구성 요소 간 상호작용, 더 깊은 모델의 학습 안정성.

논문의 마지막 절 제목은 Conclusion이 아니라 Discussion이다. 저자의 관찰과 독자의 후속 질문을 구분해 정리한다.

개인 정리 · 5분

읽은 뒤 남길 네 가지

키워드 나열보다, 근거가 붙은 문장으로 한 줄씩 작성한다.

정리할 것	작성 기준
저자가 말하고자 하는 것	대상 과제와 확인한 결과를 포함한 한 문장
이 연구에서 중요한 요소	구조·학습·데이터 중 핵심 요소와 그 이유
이해가 안 되는 부분	모르는 용어 또는 원문의 정확한 위치
추가로 공부하고 싶은 부분	다음에 읽을 주제 또는 비교해 볼 실험

개인 기록 2분 → 한 항목씩 공유 2분 → 정리 1분. 논문 읽기 기록지 또는 공책을 사용한다.

원문: Krizhevsky, Sutskever & Hinton. *ImageNet Classification with Deep Convolutional Neural Networks*. NeurIPS 2012, pp. 1097–1105.