

01 / FROM RECOGNITION TO MNIST

숫자 한 장에서, 분류의 원리까지.

무엇을 맞히는 문제인지 정하고, 사람의 단서를 CNN의 계산으로 연결한다.

CNN ① · 이미지 분류와 객체 인식

사람의 관찰 → 기초 용어 → 실제 MNIST

90분 · 설명, 관찰, 예측, 토론



이름을 붙이는 일에서, 이름을 만드는 계산까지.

SESSION MAP / 90 MIN

오늘의 길은 네 단계다.

과제의 이름을 구분한 뒤, 직관과 계산을 잇고, 실제 숫자로 확인한다.

01 문제 구분 이미지 분류·객체 인식·검출·분할은 출력이 어떻게 다른가?

02 사람의 단서 모양·부분의 관계·경험·맥락은 판단에 어떻게 관여할까?

03 계산 언어 → 04 MNIST 필터·특징 맵·채널·학습을 익히고 실제 손글씨에서 확인한다.

00-15	분류·인식·검출·분할 구분	15분
15-30	사람의 시각 단서와 맥락	15분
30-60	비유로 익히는 CNN 기초 용어	30분
60-85	실제 MNIST의 입력·학습·예측	25분
85-90	개념 연결과 출구 질문	5분

코딩 실습은 별도 선택 확장입니다. 이 시간표는 개념 수업만으로 90분을 구성합니다.

Remember 과제 15 + 사람 15 + 기초 용어 30 + MNIST 25 + 정리 5 = 90분.

01 / NAME THE TASK

이미지 분류와 객체 인식, 같은 말일까?

객체 인식은 넓은 표현이다. 무엇을 출력하는지까지 말하면 과제가 분명해진다.

객체 인식 object recognition은 영상 속 대상을 알아보는 일을 넓게 부르는 말로 쓰인다. 문맥에 따라 분류를 가리키기도 하므로 뜻을 확인해야 한다.

이미지 분류 image classification은 이미지에 클래스 라벨을 붙이는 과제다. 오늘은 숫자 한 장을 0-9 중 하나로 고르는 단일 라벨 분류를 다룬다.

대상의 종류와 위치 상자를 함께 찾는 과제는 **객체 검출 object detection**이라고 구분하자.

객체 인식 · 넓은 표현

분류 CLASSIFICATION

무엇인가 · 이미지의 라벨

검출 DETECTION

무엇이 어디에 · 물체별 상자

분할 SEGMENTATION

어떤 픽셀인가 · 영역

개념 설명용 도식 · 실제 MNIST 표본 · 측정 결과는 별도 표기

Remember “객체 인식 = 위치까지 찾기”로 단정하기보다, 분류·검출의 출력을 구체화한다.

02 / LABEL · BOX · MASK

같은 장면도, 요구하는 답이 다르다.

종류만 말할지, 위치도 찾을지, 픽셀 경계까지 나눌지 결정한다.

분류 이미지나 잘라 낸 물체에 “컵” 같은 라벨을 붙인다. 일반적인 분류 출력에는 위치 상자가 없다.

검출 물체마다 “컵 / 병”과 위치 상자를 출력한다. 여러 물체가 있을 수 있다.

분할 픽셀마다 영역을 나눈다. 의미 분할은 클래스 영역, 인스턴스 분할은 같은 클래스의 개별 물체도 구분한다.

분류



잘라 낸 컵 → 컵

검출



라벨 + 위치 상자

분할



픽셀마다 영역

예시는 과제별 정답 형태를 설명하는 도식

개념 설명용 도식 · 실제 MNIST 표본 · 측정 결과는 별도 표기

Remember 입력 사진이 같아도 정답의 형태가 다르면 다른 과제다.

함께 생각하기 “컵이 두 개다”를 알려면 클래스 이름 하나로 충분할까?


03 / FIX THE SCOPE

오늘 만들 답은 상자가 아니라 숫자다.

손글씨 한 장을 받아 0부터 9까지 중 하나의 라벨을 고른다.

사진 속 여러 숫자의 위치를 찾거나 문장 전체를 읽는 OCR
파이프라인과는 범위가 다르다. 오늘은 **한 글자씩 정리된
이미지의 분류**에 집중한다.

분류기를 이해한 뒤에는 검출·분할에도 특징 추출의 아이디어를
연결할 수 있다. 다만 출력 구조와 학습 목표는 추가로 달라진다.



한 장 → 후보 중 하나

개념 설명용 도식 · 실제 MNIST 표본 · 측정 결과는 별도 표기

Remember 과제를 먼저 정해야 라벨·출력·평가가 정해진다.

함께 생각하기 번호판 사진에서 숫자 위치를 찾는 단계와 잘라 낸 숫자를 읽는 단계는 어떻게 다를까?

04 / HUMAN RECOGNITION

사람은 다른 글씨를 어떻게 같은 7로 볼까?

획의 굵기와 기울기가 달라도 비슷한 구조를 읽을 수 있다.

가로획과 내려가는 획, 꺾이는 위치 같은 단서를 볼 수 있다. 모든 7이 같은 픽셀이나 같은 필체를 갖는 것은 아니다.

우리는 경험에서 배운 범주를 활용하고, 중요한 차이와 덜 중요한 차이를 구분한다. 하지만 한 가지 단서만으로 모든 손글씨를 완벽하게 설명할 수는 없다.



굵기 · 기울기 · 획의 추가

개념 설명용 도식 · 실제 MNIST 표본 · 측정 결과는 별도 표기

Remember 같은 범주는 하나의 완벽한 사진과 동일하다는 뜻이 아니다.

함께 생각하기 세 모양을 같은 7로 본 단서와, 서로 달라도 무시한 차이를 적어 보자.


05 / PARTS & RELATIONS

부분을 보고, 부분의 관계도 본다.

동근 획 하나보다, 어디가 열렸고 무엇이 연결됐는지가 중요할 수 있다.

3과 8을 구분할 때 곡선이 있다는 사실만으로는 부족하다. 왼쪽이 열렸는지, 고리들이 어떻게 연결되는지를 살펴볼 수 있다.

작은 획 → 더 큰 부분 → 전체 형태라는 설명은 직관을 준다.
그렇다고 사람이나 CNN의 모든 처리가 반드시 이 순서의
이름표로 나뉜다는 뜻은 아니다.



개념 설명용 도식 · 실제 MNIST 표본 · 측정 결과는 별도 표기

Remember 단서의 존재와 단서 사이의 관계를 함께 생각한다.

함께 생각하기 3의 열린 부분을 닫으면 어떤 숫자로 보일까? 한 획만 바뀌어도 의미가 달라질까?

06 / CONTEXT & LIMITS

경험과 맥락도 판단을 바꾼다.

같은 모양도 숫자 사이에서는 1, 글자 사이에서는 l로 읽을 수 있다.

인간은 주변 문맥과 경험을 함께 사용하며 애매한 입력을 해석할 수 있다. 시각 단서만으로 확신할 수 없는 경우도 있다.

이 수업의 작은 CNN은 정해진 크기의 이미지 한 장과 10개 후보를 다룬다. 사람의 경험·주의·반복 처리 전체를 복제하는 모델은 아니다.



같은 획, 다른 문맥



개념 설명용 도식 · 실제 MNIST 표본 · 측정 결과는 별도 표기

Remember 사람의 직관은 비유의 출발점이고, CNN의 동작은 실제 연산으로 확인한다.

07 / PIXEL · INPUT · LABEL

컴퓨터에게 그림은 밝기의 배열이다.

이름을 떠올리는 사람과 달리, 모델이 받는 입력은 위치별 숫자다.

픽셀은 디지털 이미지의 한 위치에 기록된 값이다. 흑백은 밝기 한 값, RGB는 색 채널 세 값을 사용할 수 있다.

입력은 이미지 배열, **라벨**은 바깥에서 붙인 정답이다. 숫자 값들을 작은 단서의 표현으로 바꾸고 그 표현에서 라벨을 예측한다.



18	18	23	26	25
19	38	178	191	25
25	41	184	204	171
29	39	163	186	151
18	22	39	45	27

한 채널을 확대한 숫자 배열

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 픽셀 안에 “7”이라는 의미가 들어 있는 것은 아니다.

함께 생각하기 숫자 하나만 보았을 때와 주변 3×3을 보았을 때 알 수 있는 것이 어떻게 다를까?

08 / AN ANALOGY, THEN AN OPERATION

사람의 표현을 계산 용어로 번역하기.

비유를 먼저 붙이고, 바로 옆에 실제 계산을 놓는다.

“작은 부분에 던지는 질문” → **필터**: 작은 가중치 묶음으로 주변 값을 곱하고 더한다.

“위치별 답을 모은 지도” → **특징 맵**: 같은 필터의 반응을 위치별로 기록한다.

“여러 관점과 넓은 단서” → **채널·수용 영역**: 표현의 축과 입력에 영향을 받는 범위다.



개념 설명용 도식 · 실제 MNIST 표본 · 측정 결과는 별도 표기

Remember 필터가 의식적으로 본다는 뜻은 아니다. 비유 뒤에 곱셈·합·배열·연결이 있다.

09 / FILTER & CONVOLUTION

필터: 작은 영역에 같은 질문을 던진다.

왼쪽 값을 빼고 오른쪽 값을 더하면 밝아지는 경계에 반응한다.

필터 / kernel은 작은 가중치 배열이다. 입력 패치와 같은 위치끼리 곱한 뒤 더하면 출력 한 칸이 된다.

이 예에서는 각 행이 $[0,0,1]$, 필터가 $[-1,0,1]$ 이므로 한 행에서 1, 세 행에서 3이 나온다. 아직 클래스 확률이 아닌 중간 반응이다.

0	0	1		-1	0	1	
0	0	1	×	-1	0	1	=
0	0	1		-1	0	1	3

현재 패치
필터

$$(-0+1) + (-0+1) + (-0+1) = 3$$

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 합성곱 층은 같은 지역 계산을 위치마다 반복한다.

함께 생각하기 패치가 모두 1이면 반응은 얼마일까? 밝음 자체와 밝기 차이를 구분해 보자.

10 / FEATURE MAP

특징 맵: 답 하나가 아니라 반응 지도.

같은 필터를 옮겨 가며 적용하면, 어디에서 반응했는지도 남는다.

비유하면 같은 질문을 이미지의 각 위치에 던져 답을 지도에 적는 것이다. 필터는 그대로이고 입력 패치가 달라진다.

평평한 밝은 곳과 경계는 다른 반응을 만들 수 있다. 밝은 특징 맵이 모든 의미에서 중요한 위치나 정답의 근거라는 보장은 없다.



$$\text{padding} = 0 \cdot \text{stride} = 1 \cdot \text{bias} = 0$$

숫자는 위 입력으로 직접 계산한 값입니다. 필터는 위치가 바뀌어도 같습니다.

Remember PDF는 고정된 첫 위치를 보여 주며, 웹에서는 필터를 직접 이동할 수 있다.


11 / CHANNELS

채널: 서로 다른 질문의 답을 나란히.

가로획을 보는 관점과 세로획을 보는 관점이 같은 위치에 함께 있을 수 있다.

필터 여러 개는 출력 특징 맵 여러 장을 만든다. 입력 RGB 채널과 출력 특징 채널은 역할이 다르다.

출력 채널 8개는 중간 반응 지도 8장이라는 뜻이다. 분류할 숫자가 8개라는 뜻도, 각각에 사람이 읽을 수 있는 이름이 붙는다는 뜻도 아니다.



입력의 색 채널

출력의 특징 채널

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 채널 수는 중간 표현의 폭, 클래스 수는 최종 후보의 수다.

12 / WEIGHT SHARING

공유: 같은 획을 다른 위치에서도 찾기.

왼쪽의 가로획과 오른쪽의 가로획에 같은 기준을 적용한다.

비유하면 같은 관찰 기준을 종이 여러 곳에 재사용하는 것이다.
위치마다 다른 필터를 새로 만드는 구조가 아니다.

흑백 입력의 3×3 필터 16개에 bias를 하나씩 두면
 $16 \times (9+1)=160$ 개 파라미터다. 출력 위치 수가 필터 수에 다시
곱해지지 않는다.

-1	0	1	-1	0	1	-1	0	1
-1	0	1	-1	0	1	-1	0	1
-1	0	1	-1	0	1	-1	0	1

9개의 값, 위치마다 재사용

출력 위치가 늘어도 새 필터가 생기는 것은 아니다.

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 이미지에 유용한 반복 규칙을 구조에 넣는 대신, 위치별 자유도에는 제약을 준다.

13 / RECEPTIVE FIELD · STRIDE · PADDING

창의 크기와 이동 간격도 정한다.

무엇을 함께 볼지, 얼마나 건너뛰지, 가장자리를 어떻게 다룰지의 선택이다.


수용 영역은 특정 출력에 영향을 줄 수 있는 입력 범위다.

시야라는 비유와 연결하되 실제로는 연결 구조로 정해진다.

stride는 창을 옮기는 간격, **padding**은 가장자리에 추가하는 값이다. stride를 키우면 공간 위치를 더 성기게 계산한다.



stride: 이동 간격



padding: 둘레 추가

영향 범위 · 이동 간격 · 경계 처리

개념 설명용 도식 · 실제 MNIST 표본 · 측정 결과는 별도 표기

Remember 3×3 필터·stride1에서 5×5 입력은 padding0이면 3×3, padding1이면 5×5 출력.


14 / RELU & POOLING

반응을 바꾸고, 주변을 요약한다.

어떤 반응을 전달할지와 얼마나 자세한 위치를 남길지 정한다.

ReLU는 음수를 0으로 바꾸고 양수는 통과시킨다. “일부 반응만 넘기기”라는 비유가 가능하지만 실제로는 $\max(0, x)$ 연산이다.

max pooling은 작은 영역의 최댓값을 남긴다. “근처에 강한 단서가 있었나”를 요약하는 대신 정확한 위치와 다른 값은 잃는다.



개념 설명용 도식 · 실제 MNIST 표본 · 측정 결과는 별도 표기

Remember 비선형 변환은 조합의 표현력을, 공간 요약은 해상도와 정보 손실을 바꾼다.

함께 생각하기 ReLU(-2,0,3)과 [1,4;2,3]의 max를 각각 말해 보자.


15 / LAYERS & CLASSIFIER

작은 획에서 더 넓은 관계로.

앞의 반응 지도를 다시 조합하면 원래 입력의 더 넓은 범위를 다룰 수 있다.

stride1·dilation1의 3×3 합성곱을 이어 붙이면 이론적 수용 영역은 3×3 → 5×5 → 7×7로 넓어진다.

그 표현을 모아 **분류기 classifier**가 후보별 점수를 만든다.
가로획 하나가 곧 숫자 7은 아니며 여러 반응의 조합을 사용한다.



stride 1 · dilation 1의 3×3 합성곱을 연결한 예

수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.


Remember 작은 질문을 연결해 넓은 관계를 계산한다. 층마다 정해진 인간식 의미가 있는 것은 아니다.

학습: 채점 결과로 기준을 조금씩 수정.

사람이 예시와 피드백으로 배운다는 직관을, 구체적인 수치 조정으로 연결한다.

logits는 클래스별 원점수, **softmax**는 합이1인 상대적 출력으로 바꾼 값이다. **loss**는 예측과 정답을 비교하는 학습 기준이다.

역전파로 가중치 변화에 대한 손실의 변화율을 계산하고, optimizer가 가중치를 수정한다. 눈·뇌의 실제 학습을 그대로 구현한 것은 아니다.



수업용 개념도 · 실제 모델의 측정 결과가 아닙니다.

Remember 구조는 사람이 설계하고, 많은 필터 값은 라벨이 있는 예시로 조정한다.

17 / MEET MNIST

이제 한 데이터셋으로 모두 연결하자.

입력 한 장에서 숫자 라벨까지, 방금 배운 용어를 같은 예제로 따라간다.

MNIST는 0-9 손글씨 숫자 이미지를 분류하는 대표적인 데이터셋이다. 이미지마다 하나의 정답 숫자가 붙어 있다.

배경과 크기가 정리된 작은 입력이므로 픽셀 → 필터 → 특징 → 점수 → 학습의 흐름을 관찰하기 좋다. 자연 사진 전체의 인식 능력을 대표하지는 않는다.



실제 표본은 다음 페이지에서

개념 설명용 도식 · 실제 MNIST 표본 · 측정 결과는 별도 표기

Remember 여기부터는 실제 MNIST 이미지와 실제로 실행한 작은 CNN 결과를 사용한다.

18 / REAL MNIST EXAMPLES

같은 숫자도 이렇게 다르게 쓴다.

열은 라벨 0-9, 행은 서로 다른 실제 표본이다.

모두 **28×28 흑백 이미지**다. 같은 숫자라도 획의 굵기·기울기·연결 모양이 다르다. 사람의 분류에서 이야기한 단서와 변화가 다시 등장한다.

공식 분할은 **train 60,000장 / test 10,000장**이다. 이 수업의 작은 실험은 그중 일부를 별도로 선택한다.



실제 MNIST test 표본 · 열은 정답 0-9, 각 열의 세 표본

Remember 한 숫자의 표본들을 보며 유지되는 구조와 달라지는 모양을 구분해 보자.


19 / FROM AN IMAGE TO A TENSOR

28×28은 컴퓨터에게 784개의 밝기다.

사람이 7이라고 읽는 모양을 모델은 [1,28,28] 배열로 받는다.

그림의 작은 창을 확대하면 실제 밝기 값 0-255를 볼 수 있다.
실습에서는 255로 나누어 0-1 범위로 바꾼다.

숫자 라벨 7과 밝기 값 7은 역할이 다르다. 전자는 정답 범주이고
후자는 한 픽셀의 세기다. 배치로 묶으면 [B,1,28,28]이 된다.



실제 MNIST test 표본 · 6×6 픽셀 밝기 확대

Remember shape는 배열의 모양, label은 맞혀야 할 의미다.

20 / TRAIN · VALIDATION · TEST

연습·점검·시험을 섞지 않는다.

수업용 실험의 예산을 정한 뒤, 마지막 test는 가중치 조정에 쓰지 않는다.

공식 train에서 클래스마다 600장씩 **학습 6,000장**, 서로 겹치지 않는 100장씩 **검증 1,000장**을 선택한다. 나머지 53,000장은 이 실험에서 쓰지 않는다.

공식 test에서는 클래스마다 100장씩 **평가 1,000장**을 고정한다. seed 17 · 6epoch · 같은 작은 CNN으로 학습하고 마지막 epoch를 평가한다.



개념 설명용 도식 · 실제 MNIST 표본 · 측정 결과는 별도 표기

Remember 뒤의 수치는 공식 test 10,000장 전체 성능이 아니라 고정한 1,000장 부분집합 결과다.


21 / MNIST THROUGH TWO FILTERS

숫자에 필터를 대면 획의 변화가 보인다.

실제 손글씨 한 장에 좌우·상하 차이 필터를 적용했다.

왼쪽은 실제 입력, 가운데와 오른쪽은 **사람이 정한** 차이 필터의 계산 결과다. 색의 부호와 크기는 밝기 변화의 방향과 정도를 나타낸다.

이 단계에서 필터는 “7이다”라고 말하지 않는다. 중간 단서를 위치별로 기록한다. 실제 CNN의 학습된 필터가 이 두 규칙과 똑같아야 하는 것은 아니다.



실제 입력에 수작업 필터를 적용한 계산 · 학습된 필터 아님

Remember 필터 반응 → 특징 맵이라는 용어를 실제 픽셀 변화에 연결한다.

함께 생각하기 가로획과 기울어진 획은 어느 지도에서 어떻게 보이는가?


22 / THE ACTUAL MODEL

작은 CNN 안에서 크기가 어떻게 바뀔까?

흑백 입력 → 특징8장 → 특징16장 → 숫자 후보10개.

3×3 Conv·ReLU 뒤에 2×2 max pooling을 둔다. 공간 크기는 **28×28 → 14×14 → 7×7**로 줄어든다.

마지막 16×7×7 특징을 펼쳐 선형 분류기에 넣고 0-9의 점수10개를 만든다. 이 모델의 학습 파라미터는 **9,098개**다.



학습할 파라미터 9,098개

개념 설명용 도식 · 실제 MNIST 표본·측정 결과는 별도 표기

Remember CNN 층은 특징을 만들고, 분류기는 그 표현을 숫자별 점수로 연결한다.


23 / MEASURED LEARNING

실제로 학습시키면 곡선이 움직인다.

필터와 분류 가중치를 정답 숫자에 맞춰 함께 조정한 결과다.

실행 조건 CPU·seed17·Adam(lr0.003)·batch128·6epoch.
학습 CE는 1.322에서 0.116로 변했다.

왼쪽은 학습/검증 손실, 오른쪽은 검증 정확도다. 정확도는 정답 여부, 손실은 정답에 부여한 점수까지 반영하므로 같은 값이 아니다.



실측 학습 곡선 · train 6,000 / validation 1,000 · seed 17 · CPU

Remember 이 곡선은 실제 실행 결과다. 다른 초기값·환경·예산에서도 같은 수치가 보장되지는 않는다.


24 / SCORES TO A LABEL

한 장에서 10개 점수, 그중 하나의 예측.

실제 test 표본 하나의 예측과 softmax 출력을 함께 본다.

이 모델은 고정 test 1,000장에서 **95.3%**를 맞혔다. 오른쪽 막대는 한 표본에서 후보 0-9에 준 softmax 값이다.

큰 막대가 예측 라벨을 정하지만, 그 값이 현실의 정답률과 언제나 일치하거나 낮은 입력을 잘 거른다는 뜻은 아니다. 사진 속 숫자 위치를 찾는 검출 결과도 아니다.



실제 test 표본의 모델 출력 · 6epoch 최종 모델


Remember 분류 출력은 후보별 점수와 라벨이다. 실제 위치 상자나 픽셀 마스크를 출력하지 않았다.

25 / FIVE-MINUTE DISCUSSION

활동: 사람의 단서로 오분류를 읽어 보자.

다음은 실제 test 오분류 중 앞의 여섯 장이다. 전체의 대표 표본은 아니다.

- ① **1분** 한 장을 골라, 라벨과 모델 예측을 비교한다. 어떤 획이 애매하게 보이는지 관찰한다.
- ② **2분** “필터·특징 맵·수용 영역” 중 두 단어로 확인해 볼 가설을 만든다. 그림만으로 내부 원인을 확정하지 않는다.
- ③ **2분** 획 일부를 가리거나 위치를 바꾸는 등, 가설을 시험할 변화를 하나 제안한다.



실제 고정 test 오분류 앞 6장 · 전체를 대표하는 표본 아님

Remember 맞힌 비율을 넘어서, 어떤 변화에서 실패하는지 질문하면 다음 실험이 된다.

RECAP / KEEP THE CONNECTIONS

과제 → 사람 → 용어 → MNIST.

한 흐름으로 설명할 수 있으면 이름을 외우는 단계를 넘어서는 것이다.

과제 분류는 라벨, 검출은 물체별상자, 분할은 픽셀 영역. 객체 인식이라는 말은 문맥을 확인한다.

직관과 계산 사람의 단서 관찰을 필터·특징 맵·계층의 비유로 연결하되 실제 연산과 구분한다.

MNIST 28×28 입력에서 10개 점수를 만들고 정답으로 가중치를 조정했다. 다음 주는 맞힌 근거를 시험한다.

01 / Torchvision · Classification / Detection / Segmentation

<https://docs.pytorch.org/vision/stable/models.html>

02 / MNIST · 데이터 구성과 공식 분할

<https://www.tensorflow.org/datasets/catalog/mnist>

03 / Torchvision MNIST · 공식 로더와 데이터 미러

https://docs.pytorch.org/vision/stable/_modules/torchvision/datasets/mnist.html

04 / LeCun et al. (1998) · Gradient-Based Learning Applied to Document Recognition

<https://bottou.org/papers/lecun-98h>

Remember 출구 질문: 필터 반응은 숫자 확률인가? 출력 채널 수는 클래스 수인가? MNIST 분류기가 숫자 위치도 찾았나?

논문 읽기 · CNN

AlexNet (2012)

ImageNet Classification with Deep Convolutional Neural Networks

ImageNet Classification with Deep Convolutional Neural Networks

논문 제목 · 원문 1쪽 ↗

Alex Krizhevsky · Ilya Sutskever · Geoffrey E. Hinton

Advances in Neural Information Processing Systems 25

CNN 복습

필터 → 특징 → 분류

논문 분석

문제 → 구조 → 학습

결과 해석

실험 → Discussion → 기록

90분 · 복습 6페이지 + 논문 분석 15페이지

CNN 복습 · 1 / 6

이미지 분류의 입력과 출력

이미지 한 장을 받아, 정해진 클래스마다 점수를 계산한다.

이미지	CNN	분류 점수
높이 × 너비 × 채널	학습한 특징으로 변환	클래스 수만큼 출력
	MNIST	AlexNet의 분류 과제
입력	28 × 28 × 1 · 흑백 숫자	RGB 자연 이미지
출력	숫자 0-9 · 10개 점수	ILSVRC · 1,000개 클래스 점수
정답	이미지당 클래스 라벨	이미지당 클래스 라벨


이미지 분류는 “어떤 클래스인가”를 예측한다. 물체의 위치를 찾는 객체 검출과는 출력이 다르다.

CNN 복습 · 2 / 6

합성곱: 같은 필터를 여러 위치에 적용

필터는 사람이 정한 체크리스트가 아니라, 학습으로 값이 바뀌는 가중치 배열이다.

작은 영역을 보고, 같은 질문을 옮긴다



입력의 3 × 3 영역

수업용 손계산 · 실제 학습에서는 필터 값 자체가 바뀐다.

수업용 재구성 · 논문 원문 그림과 구별

국소 연결

입력 전체가 아닌 작은 영역을 한 번에 본다.

가중치 공유

같은 필터를 이동하며 사용한다. 위치마다 새 필터를 만들지 않는다.

특징 맵

각 위치에서 계산한 반응값을 공간에 맞춰 모은 결과.

반응값 = $\Sigma(\text{입력값} \times \text{필터 가중치}) + \text{편향}$


그림은 수업용 손계산 예제. 실제 필터의 값은 정답과 예측의 차이를 줄이는 방향으로 학습한다.

CNN 복습 · 3 / 6

채널과 깊이: 여러 반응을 조합

필터 하나가 출력 채널 하나를 만들고, 다음 층은 그 채널들을 함께 읽는다.

RGB는 입력 채널, 필터 개수는 출력 채널



입력: 3개 채널

출력: 여러 특징 맵

하나의 $11 \times 11 \times 3$ 필터 → 한 출력 채널

수업용 재구성 · 논문 원문 그림과 구별

채널

첫 입력은 R·G·B. 이후 채널은 학습한 필터에 대한 반응이다.

깊이

뒤쪽 층은 앞쪽 층의 반응을 조합한다.

수용 영역

한 반응에 영향을 주는 원본 이미지의 범위. 층을 거치며 넓어질 수 있다.

사람이 획과 모양의 관계를 보는 것에 비유할 수 있다. 다만 특정 채널이 반드시 “눈”이나 “귀”를 뜻하는 것은 아니다.

CNN 복습 · 4 / 6

ReLU와 pooling의 역할

ReLU는 값에 비선형 규칙을 적용하고, pooling은 주변 반응을 요약한다.

$$\text{ReLU}(x) = \max(0, x)$$


$-2 \rightarrow 0 \cdot 0 \rightarrow 0 \cdot 3 \rightarrow 3$

음수는 0으로, 양수는 그대로 통과시킨다. 여러 층이 복잡한 관계를 학습하도록 비선형성을 넣는다.

Stride는 창을 옮기는 간격.

Padding은 가장자리에 더하는 값.

3 × 3 창을 2칸씩 이동: 영역이 겹친다



수업용 예제 · 같은 채널 안에서 주변 반응을 요약

수업용 재구성 · 논문 원문 그림과 구별

Max pooling은 각 채널 안에서 최댓값을 남긴다. 위치 정보를 일부 줄이지만 모든 이동에 같은 출력을 보장하지는 않는다.

CNN 복습 · 5 / 6

분류와 학습: 정답 확률을 높이는 과정

예측에 사용한 필터와 분류기의 가중치를 같은 손실로 함께 학습한다.

CNN + 분류기

클래스별 점수 z

Softmax

점수 $\rightarrow$ 확률 p

손실

정답 확률이 작으면 큰 값

$$p(k | x) = \exp(z_k) / \sum_j \exp(z_j) \quad L = -\log p(y | x)$$

수업용 표기 · y 는 정답 클래스. AlexNet § 3.5의 정답 로그확률 최대화를 손실 최소화로 쓴 형태.

순전파에서 예측과 손실을 계산한다. 역전파로 가중치별 기울기를 구하고, 옵티마이저로 가중치를 갱신한다.

정답 확률 0.8과 0.2 중에서는 0.2일 때 손실이 더 크다. 추론에서는 입력으로 예측만 계산한다.

CNN 복습 · 6 / 6

일반화: 처음 보는 이미지에서도 맞히기

훈련 성능만으로는 모델이 새로운 이미지에 잘 적응되는지 알 수 없다.

데이터 구분	역할	주의할 점
Train · 훈련	가중치 갱신	이 데이터에서만 잘 맞힐 수 있다
Validation · 검증	모델·학습 설정 선택	설정 선택에 사용했다면 최종 시험과 구분
Test · 시험	최종 성능 평가	시험 결과로 설정을 반복 조정하지 않는다

과적합

훈련 데이터에 지나치게 맞춰져, 새로운 데이터에서는 성능이 떨어지는 현상.

대응 방법

데이터 증강, dropout, weight decay 등. 효과는 검증·시험 조건과 함께 확인한다.

원문 읽기 · 문제와 제안

Abstract · Introduction

현실의 이미지에는 변형이 많다. 큰 데이터와 큰 모델을 어떻게 함께 쓸 것인가?

원문의 논리	이 논문에서 읽을 내용
기존 문제	작은 데이터만으로는 현실 이미지의 다양한 모양·배경·조명을 다루기 어렵다.
필요한 조건	많은 라벨 데이터, 표현력이 큰 모델, 과적합 억제, 감당 가능한 학습 시간.
제안	깊은 CNN을 GPU로 학습하고 ReLU·증강·dropout 등을 함께 사용한다.
확인할 근거	구조는 Figure 2, 성능은 Tables 1-2, 구성 요소의 근거는 § § 3-4.

초록의 성능 수치는 결론의 예고다. 단일 모델인지, 어떤 데이터와 지표인지 실험 절에서 다시 확인한다.

§ 2 · § 3.5

The Dataset · 문제 정의

RGB 이미지 한 장을 1,000개 클래스 중 하나로 분류한다.

조건	논문의 설정
데이터	ImageNet의 ILSVRC 부분집합
규모	훈련 약 120만 · 검증 5만 · 시험 15만 장
입력 처리	256 × 256으로 정리 후 224 × 224 crop
학습 목표	정답 클래스의 로그확률을 높인다

Top-1 error

가장 높은 점수의 클래스가 정답과 다른 비율.

Top-5 error

점수가 높은 5개 클래스 안에 정답이 없는 비율.

비교 조건

ILSVRC-2010과 2012, 검증과 시험 결과를 나눠 읽는다.

독립된 Problem statement 절은 없다. § § 1·2·3.5에서 입력·출력·목표를 모아 재구성한 것이다.

§ 3.5 · Figure 2

The Architecture

가중치가 있는 8개 층: 합성곱 5개 + 완전연결 3개.




Figure 2 · 두 GPU에 나누어 배치한 하나의 네트워크 · 원문 5쪽 ↗

Conv 1-5

국소 특징과 그 조합

FC 6-8

4,096 → 4,096 → 1,000

Softmax

1,000개 클래스의 확률

ReLU·pooling·정규화는 “8개 학습 층”과 별도로 읽는다. 그림의 위·아래는 GPU 분할이며, 독립 모델의 앙상블이 아니다.

§ 6.1 · Figure 3

첫 합성곱 층은 무엇을 학습했나

96개의 $11 \times 11 \times 3$ 필터를 학습한 뒤 시각화한 결과다.




Figure 3 · 첫 층의 학습된 필터 · 원문 6쪽 ↗

보이는 것

서로 다른 방향·주파수의 패턴과 색 반응이 나타난다.

그림의 대상

입력 이미지도, 특징 맵도 아니다. 학습된 필터 가중치다.

채널과 연결

필터 하나는 RGB 3개 채널을 함께 읽고, 한 출력 채널을 만든다.

위·아래 48개씩은 서로 다른 GPU에 배치된 필터다. 초기 층 그림만으로 모든 층의 의미를 설명할 수는 없다.

§ 3.1 · Figure 1

ReLU: 학습 속도의 근거

양수 영역에서 포화되지 않는 활성화가 학습 진행에 어떤 차이를 만드는가?




Figure 1 · 훈련 오류율과 epoch · 원문 3쪽 ↗

실험 설정

CIFAR-10 · 4층 CNN · ReLU(실선)와 tanh(점선).

관찰

훈련 오류율 25%에 도달하는 epoch가 ReLU에서 약 6배 적다.

해석 범위

ImageNet 최종 정확도 비교가 아니다. 학습률은 각각 선택했다.

$$f(x) = \max(0, x)$$

개념 → 수식 → 그래프 순서로 확인. “항상 벽시계 시간 6배 단축”으로 일반화하지 않는다.

§ 3.3 · § 3.4

LRN과 overlapping pooling

LRN은 채널 간 반응을 조절하고, pooling은 같은 채널의 주변 위치를 요약한다.


$$b_{x,y}^i = a_{x,y}^i / \left(k + \alpha \sum_{j=\max(0,i-n/2)}^{\min(N-1,i+n/2)} (a_{x,y}^j)^2 \right)^\beta$$

§ 3.3 · LRN 원문 수식 · 원문 4쪽 ↗

LRN

같은 위치에서 인접한 채널들의 반응 제곱합으로 나눈다. 주변 반응이 클수록 출력이 줄어드는 형태다.

3 × 3 창을 2칸씩 이동: 영역이 겹친다



수업용 예제 · 같은 채널 안에서 주변 반응을 요약

수업용 재구성 · 논문 원문 그림과 구별

Overlapping max pooling

3 × 3 창을 stride 2로 이동한다. 이웃한 창이 일부 영역을 공유한다.

LRN은 첫째·둘째 합성곱 층의 ReLU 뒤에 적용한다. 배치 평균·분산을 사용하는 BatchNorm과 다른 연산이다.

§ 4 · Data augmentation / Dropout

Reducing Overfitting

약 6천만 개의 파라미터를 가진 모델은 120만 장으로도 과적합할 수 있었다.

방법	논문의 설정	목적
공간 증강	256 × 256에서 무작위 224 × 224 crop + 좌우 반전	위치·방향 변화에 대응
색 증강	RGB 값의 주성분을 이용한 색 변화	조명·색 변화에 대응
Dropout	첫 두 FC 층의 은닉 출력을 확률 0.5로 0 처리	특정 은닉 단위 조합에 대한 의존 완화

학습과 시험을 구분한다. 학습에서는 무작위 crop을 사용한다. 시험에서는 5개 위치와 그 좌우 반전, 총 10개 crop의 예측 확률을 평균한다.

증강은 라벨 의미를 보존한다는 가정이 필요하다. Dropout은 학습 중 사용하고, 평가에서는 모든 은닉 단위를 사용한다.

§ 5 · 학습 조건

Details of Learning

구조만 같다고 같은 결과가 나오는 것은 아니다.

항목	논문의 설정	읽을 때 확인할 점
최적화	SGD · batch 128 · momentum 0.9	가중치를 어떻게 갱신했는가
규제	Weight decay 0.0005	손실과 함께 어떤 제약을 두었는가
학습률	0.01에서 시작, 검증 성능 정체 시 10분의 1	시험 데이터가 아닌 검증 성능으로 조절
학습량	약 90 epochs	데이터를 몇 번 반복해 보았는가
계산 자원	GTX 580 3GB 2개 · 약 5-6일	당시 메모리와 시간이 구조 선택을 제한

SGD·momentum·weight decay의 세부 식보다 각 설정의 역할을 먼저 읽는다. 재현 단계에서는 초기화와 전처리까지 확인한다.

§ 6 · Table 1

ILSVRC-2010: 이전 방법과의 비교

같은 시험 지표에서 제안한 CNN의 오류율을 비교한다.

Model	Top-1	Top-5
<i>Sparse coding [2]</i>	47.1%	28.2%
<i>SIFT + FVs [24]</i>	45.7%	25.7%
CNN	37.5%	17.0%

Table 1 · ILSVRC-2010 시험 오류율 · 원문 7쪽 ↗

Top-5 시험 오류율

SIFT + Fisher Vectors 25.7% → CNN 17.0%.

차이의 크기

8.7%p 감소. 상대 감소율로 계산하면 약 33.9%.

이 표는 최종 시스템의 성능 비교다. 개선분 전체를 ReLU나 dropout 한 가지의 효과라고 해석할 수는 없다.

§ 6 · Table 2

ILSVRC-2012: 단일 모델과 앙상블

행의 모델 조건과 열의 validation / test 구분을 함께 읽는다.

Model	Top-1 (val)	Top-5 (val)	Top-5 (test)
<i>SIFT + FVs [7]</i>	—	—	26.2%
1 CNN	40.7%	18.2%	—
5 CNNs	38.1%	16.4%	16.4%
1 CNN*	39.0%	16.6%	—
7 CNNs*	36.7%	15.4%	15.3%

Table 2 · ILSVRC-2012 오류율 · 원문 7쪽 ↗

1 CNN

Top-5 검증 **18.2%**. 시험값은 이 행에 없다.

7 CNNs*

Top-5 시험 **15.3%**. 여러 모델의 예측을 평균했다.

*의 의미

추가 ImageNet 데이터로 지도 사전학습한 모델을 포함한다.

7개는 일반 모델 5개 + 추가 사전학습 모델 2개다. 18.2% → 15.3%를 앙상블만의 효과로 계산하면 평가 집합과 학습 조건까지 섞인다.

§ 3-4 · 구성 요소 비교

각 구성 요소는 얼마나 기여했나

최종 점수와 별개로, 무엇을 바꿔 비교했는지 본문에서 찾는다.

비교	논문이 보고한 변화	해석할 때의 조건
LRN 사용	Top-1 / Top-5 오류 1.4 / 1.2%p 감소	LRN 유무 비교 · § 3.3
겹치는 pooling	0.4 / 0.3%p 감소	3×3 vs 2×2 , stride 2 · § 3.4
두 GPU의 큰 모델	1.7 / 1.2%p 감소	한 GPU의 더 좁은 모델과 비교 · § 3.2
중간 합성곱 층 제거	Top-1 성능 약 2%p 손실	깊이를 줄인 모델의 관찰 · § 7

각 숫자를 더해 전체 성능 향상을 설명할 수는 없다. 구성 요소는 서로 영향을 주며, GPU 비교는 모델 크기도 함께 달라진다.

확장 질문: 데이터·학습 예산을 고정하고 한 요소씩 바꾸면 같은 경향이 나오는가?

§ 6.1 · Figure 4 왼쪽

예측 사례: 무엇을 맞히고 틀렸나

원문이 고른 8개 시험 이미지의 상위 5개 예측을 살펴본다.



Figure 4 왼쪽 · Top-5 예측 · 원문 8쪽 ↗

읽는 순서

이미지 → 후보 클래스 → 확률 → 정답 표시.

관찰

물체가 중심에 없거나 장면에 여러 의미가 있을 때의 예측을 확인한다.

주의

그럴듯한 답과 데이터셋의 정답은 다를 수 있다. 8개 사례로 오류 유형의 빈도를 알 수는 없다.

§ 6.1 · Figure 4 오른쪽

은닉 표현: 어떤 이미지가 가까운가

픽셀 대신 마지막 은닉층의 4,096차원 벡터로 거리를 계산한다.




Figure 4 오른쪽 · 시험 이미지와 가까운 훈련 이미지 6개 · 원문 8쪽 ↗

첫 열은 시험 이미지.

나머지 열은 은닉 표현의 유클리드 거리가 가까운 훈련 이미지.

자세와 배경이 달라도 비슷한 물체가 가까울 수 있다. 분류를 위해 학습한 표현의 성질을 살펴보는 분석이다.

이웃 검색은 결과를 이해하기 위한 분석이다. AlexNet의 기본 분류 절차가 최근접 이웃 검색이라는 뜻은 아니다.

§ 7 · 주장의 범위와 남은 문제

Discussion

큰 깊은 CNN을 대규모 이미지 분류에 적용했을 때 얻은 성능 개선을 정리한다.

저자가 강조하는 결과

깊이가 중요했고, 중간 합성곱 층을 줄이면 성능이 나빠졌다.

계산 자원의 제약

모델 크기는 GPU 메모리와 감당 가능한 학습 시간의 영향을 받았다.

후속 방향

더 큰 모델과 데이터, 비디오의 시간 구조를 활용하는 학습.

이 논문에서 확인한 범위

해당 ImageNet 분류 설정에서 구조와 학습 기법을 함께 사용한 결과.

추가 검증이 필요한 것

새 도메인에서의 일반화, 구성 요소 간 상호작용, 더 깊은 모델의 학습 안정성.

논문의 마지막 절 제목은 Conclusion이 아니라 Discussion이다. 저자의 관찰과 독자의 후속 질문을 구분해 정리한다.

개인 정리 · 5분

읽은 뒤 남길 네 가지

키워드 나열보다, 근거가 붙은 문장으로 한 줄씩 작성한다.

정리할 것	작성 기준
저자가 말하고자 하는 것	대상 과제와 확인한 결과를 포함한 한 문장
이 연구에서 중요한 요소	구조·학습·데이터 중 핵심 요소와 그 이유
이해가 안 되는 부분	모르는 용어 또는 원문의 정확한 위치
추가로 공부하고 싶은 부분	다음에 읽을 주제 또는 비교해 볼 실험

개인 기록 2분 → 한 항목씩 공유 2분 → 정리 1분. 논문 읽기 기록지 또는 공책을 사용한다.

원문: Krizhevsky, Sutskever & Hinton. *ImageNet Classification with Deep Convolutional Neural Networks*. NeurIPS 2012, pp. 1097–1105.