

CNN을 안다는 것에서, 논문을 읽는 것으로.

구조를 외우기보다, 저자의 질문과 근거를 따라가는 90분.

AlexNet

Alex Krizhevsky · Ilya Sutskever

Geoffrey E. Hinton


NeurIPS 2012

1주치의 필터·특징 맵·분류기를

실제 연구의 설계 선택으로 다시 읽습니다.

ORIGINAL PAPER

p. 5 · Figure 2 ↗



원문 PDF 직접 캡처 · 주변 본문/캡션 생략 · 아래 설명은 수업용 해설

오늘의 목표: 논문의 주장을 근거와 함께 설명하기

Read & think 초록·서론 → 문제 정의 → 개념 → 수식 → 실험 → 결론 → 나의 정리

오늘의 읽기 순서가, 발표의 순서다.

논문 목차를 그대로 낭독하지 않고, 이해에 필요한 질문 순서로 재배치합니다.

첫 번째 통과

무슨 문제를 왜 풀었는지 잡습니다.

두 번째 통과

방법을 개념으로 설명하고 수식으로 확인합니다.

세 번째 통과

실험이 주장을 지지하는 범위를 정리합니다.

00-08 읽기 준비 · 질문과 근거를 구분

08-20 초록 + Introduction · 문제와 제안

20-30 Problem statement · 입력 · 목표 · 조건

30-58 핵심 개념 · CNN은 왜 이렇게 설계했나

58-65 수식 확인 · 이미 이해한 연산에 기호 붙이기

65-80 실험 분석 · 표 · 그림 · 비교 조건

80-83 Discussion · 주장과 범위

83-90 나의 정리 · 네 가지 질문

Read & think 모든 문장을 처음부터 완벽히 이해하려 하지 말고, 다음에 확인할 질문을 남깁니다.

읽으면서 세 종류의 메모를 남긴다.

“저자가 말했다”와 “실험에서 확인했다”와 “내가 추측했다”를 나눕니다.

01

주장 C

저자가 무엇을 가능하게 했다고 말하는가?

예: 이 구조가 대규모 이미지 분류에 유효하다.

02

근거 E

그 주장을 어디서 확인할 수 있는가?

기록: 절, 표·그림 번호, 데이터와 비교 조건.

03

질문 Q

지금 모르는 점은 무엇인가?

예: 층 수 때문인가, 학습 방식 때문인가?

Read & think 모르는 단어만 모으는 대신, 주장과 근거 사이에 남는 질문을 적습니다.

함께 읽기 “성능이 좋아졌다”는 문장 옆에 반드시 적어야 할 조건은 무엇일까요?

BEFORE THE ABSTRACT

3 MIN

제목에서 약속을 찾고, 목차에서 경로를 찾는다.

무엇을 분류하고, 어떤 방법을 쓰며, 무엇을 아직 말하지 않았는가?

ORIGINAL PAPER

p. 1 · 논문 제목 ↗

ImageNet Classification with Deep Convolutional Neural Networks

원문 PDF 직접 캡처 · 주변 본문/캡션 생략 · 아래 설명은 수업용 해설

01

ImageNet

어떤 데이터인가



02

Classification

출력은 클래스



03

Deep CNN

깊은 합성곱 신경망

읽을 위치

Abstract · § 1 → § 2 · § 3.5 → § 3-5 → § 6 → § 7 Discussion

Read & think 이 논문은 CNN을 처음 발명한 논문이 아닙니다. 제목만으로 기여를 단정하지 않습니다.

함께 읽기 1주차의 MNIST에서 자연 이미지로 가면, 입력에서 어떤 변화가 더 커질까요?

PASS 1 / ABSTRACT

3 MIN

초록은 번역문보다, 질문의 지도다.

첫 문장의 “무엇을 했다”를 찾고, 방법·결과·조건으로 나눠 읽습니다.

ORIGINAL PAPER

p. 1 · Abstract 첫 구절 일부 ↗

We trained a large, deep convolutional neural network

원문 PDF 직접 캡처 · 주변 본문/캡션 생략 · 아래 설명은 수업용 해설

01

문제·대상

많은 종류의 자연 이미지를 분류한다.

02

방법

깊은 CNN과 이를 학습시키는 선택들.

03

결과·조건

오류율을 보고하되, 연도·지표·모델 구성을 확인한다.

먼저 추출할 것: 입력 / 출력 / 제안 / 비교 결과. 모르는 세부 용어는 Q로 표시.

Read & think

초록은 논문의 주장 지도입니다. 숫자의 정확한 조건은 본문에서 다시 확인합니다.

함께 읽기 초록의 큰 성과가 “모든 CNN” 또는 “모든 이미지”에 대한 약속일까요?

PASS 1 / THE EXISTING PROBLEM

3 MIN

Introduction: 쉬운 데이터의 성공이 끝은 아니다.

숫자를 잘 읽는 모델이 복잡한 자연 이미지도 잘 분류한다는 보장은 없습니다.

ORIGINAL PAPER

p. 1 · §1 제목 ↗

1 Introduction

원문 PDF 직접 캡처 · 주변 본문/캡션 생략 · 아래 설명은 수업용 해설

01

MNIST에서 생각하기

작은 흑백 입력, 비교적 정돈된 대상.

02

자연 이미지에서 생각하기

배경·조명·자세·크기·가림이 함께 달라짐.

독자의 질문 ①

이전 데이터와 방법은 어떤 변화를 충분히 다루지 못했을까?

독자의 질문 ②

예시를 많이 모으면, 모델 크기·계산량·과적합 문제는 어떻게 달라질까?

서론을 읽는 목적

새 기법 이름 전에, 저자가 중요하게 본 병목을 찾습니다.

Read & think 배경 설명을 읽을 때는 “그래서 무엇이 부족한가?”를 한 문장으로 적습니다.

PASS 1 / REQUIREMENTS

2 MIN

필요한 것은 하나가 아니라, 함께 맞는 조건들.

데이터·표현력·학습 가능성·일반화가 서로를 제한합니다.

01

다양한 예시

관찰하지 못한 변화까지 완전히 알 수는 없다.
학습 데이터가 담는 범위를 확인한다.

02

충분한 표현력

여러 시각 단서를 조합할 모델이 필요하다.
깊이와 채널 수는 설계 변수다.

03

실제로 학습 가능

계산·메모리와 과적합을 함께 다뤄야 한다.
크게 만들기만 해서는 충분하지 않다.

Read & think “무엇이 필요하다”와 “이 논문이 그것을 어떻게 마련했다”를 연결합니다.

함께 읽기 모델만 키웠는데 학습 시간이 너무 길어진다면, 표현력만의 문제일까요?

기여를, 문제와 해결책의 짝으로 바꾼다.

새 이름을 외우는 대신, 각 선택이 겨냥하는 문제를 붙여 봅니다.

읽을 문제	논문에서 확인할 선택	우리의 확인 질문
이미지의 규칙을 활용	합성곱과 계층 구조	공유되는 것과 달라지는 것은?
큰 모델의 학습 비용	ReLU · GPU 구현	속도 비교의 데이터와 지표는?
훈련 예시를 과하게 기억	데이터 증강 · Dropout	학습/평가 때 무엇이 다른가?
정말 개선되었는가	벤치마크 · 구성 요소 비교	정확히 어느 조건이 바뀌었는가?

Read & think 한 가지 마법의 기법보다, 문제를 풀 수 있도록 구성한 시스템을 읽습니다.

CHECKPOINT / 2 MIN

2 MIN

잠깐 멈춤: 아직 구조도는 보지 않는다.

두 문장이 나오면 초록·서론의 첫 읽기는 성공입니다.

01

기존 문제

“기존에는 _____ 때문에
_____ 하기가 어려웠다.”

02

필요한 것과 제안

“이를 위해 _____가 필요하며,
이 논문은 _____를 제안·구성했다.”

짜과 확인하기

문장에 ReLU·Dropout을 넣었다면, 그 이름이 어떤 문제를 해결하는지도 설명해 보세요.

Read & think 설명하지 못한 빈칸은 실패가 아니라, 다음 절에서 확인할 질문입니다.

PASS 2 / RECONSTRUCT THE PROBLEM

2 MIN

Problem statement라는 제목이 없어도 읽을 수 있다.

AlexNet에는 독립된 “Problem statement” 절이 없습니다. 정보를 모아 재구성합니다.

01

입력 → 출력

한 장의 RGB 이미지

→ 클래스별 점수·확률과 예측 라벨

02

최적화 목표

훈련 예시의 정답 라벨에

높은 확률을 주도록 가중치를 학습

03

성공의 기준

분리된 평가 데이터의 오류율

+ 실제 학습에 필요한 계산 조건

근거 위치: § 1 동기 · § 2 데이터와 지표 · § 3.5 출력/목표 · § 5 학습 조건

Read & think

저자의 문장을 찾아서 입력·출력·목표·제약을 채우는 것이 문제 정의 분석입니다.

PROBLEM / DATA & PROTOCOL

3 MIN

데이터셋 이름 뒤에 숨은 조건을 펼친다.

ImageNet 전체와 ILSVRC 대회 부분집합, 그리고 대회 연도를 구분합니다.

데이터 이름만 적으면 부족합니다.

어떤 버전인가? 몇 개 클래스를 쓰는가? 어떤 분할에서 평가하는가?

원문 §2를 확인합니다.

이 논문이 설명하는 대회 과제는 1,000개 범주입니다. 2010과 2012 결과는 뒤에서 별도로 읽습니다.

기록할 칸	혼동을 막는 질문
데이터 버전	전체 ImageNet인가, 대회 부분집합인가?
훈련 / 검증 / 시험	가중치 학습·설정 선택·최종 평가 중 무엇인가?
추가 데이터	사전학습에 더 큰 데이터가 사용되었는가?
평가 입력	한 이미지의 한 crop인가, 여러 crop인가?

Read & think 비교의 단위는 모델 이름 하나가 아니라, 모델·데이터·평가 절차의 묶음입니다.

함께 읽기 2010 시험 오류율과 2012 검증 오류율을 같은 표의 순위처럼 비교해도 될까요?

Top-1과 Top-5: 질문이 달라지면 오류도 달라진다.

정답이 첫 번째인가, 다섯 후보 안에 있는가?

순위	1	2	3	4	5
수업용 예측	개	고양이	여우	늑대	곰

01 정답 = 고양이 Top-1: 틀림 Top-5: 맞음	02 정답 = 말 Top-1: 틀림 Top-5: 틀림	03 오류율 틀린 이미지 수 ÷ 전체 이미지 수 낮을수록 좋음
---	---	--

Read & think Top-5 오류율 15.3%를 “정확도 15.3%” 또는 “Top-1 오류율”로 읽지 않습니다.

우리 말로 다시 쓴, 이 연구의 문제.

논문에 그대로 있는 인용문이 아니라, 지금까지 읽은 내용을 연결한 문장입니다.

다양한 자연 이미지에서
분류에 유용한 시각 표현을 배우되,
큰 모델을 학습할 수 있는 계산 조건과
새 이미지에 대한 성능을 함께 확보할 수 있을까?

고정할 것: 과제·평가 조건 / 바꿀 것: 구조·학습 방식 / 확인할 것: 결과와 비용

Read & think 이제부터 모든 기법을 이 문제의 어느 부분에 답하는지 연결해 읽습니다.

함께 읽기 이 질문에서 “새 이미지”를 빼면 무엇을 놓치게 될까요?

핵심 theory를, 설계 원리로 먼저 읽는다.

이 논문의 중심은 새로운 정리의 증명보다, 구조·학습 방식과 그 경험적 검증입니다.

01

국소성

가까운 픽셀의 관계에서
작은 시각 단서를 계산한다.

02

가중치 공유

같은 단서를 다른 위치에서도
같은 규칙으로 계산한다.

03

계층적 조합

단서의 반응을 다음 층에 전달해
더 넓은 관계를 조합한다.

사람에 비유하면

작은 영역에서 획을 보고, 다른 위치에서도 같은 획을 찾고, 획들의 관계를 보는 과정. 단, CNN이 사람의 인지 과정을 그대로 복제했다는 뜻은 아닙니다.

필터는 “이 근처에 이런 패턴이 있는가?”라는 질문.

입력의 작은 영역과 가중치를 곱해 더하면, 한 위치의 반응값이 나옵니다.

질문을 담는 숫자

필터의 가중치가 어떤 대비·패턴에 크게 반응할지 정합니다.

질문을 옮기기

같은 필터를 이동해 얻는 반응의 지도가 특징 맵입니다.

학습

정답과의 오차를 이용해 필터 값도 바꿉니다.

작은 영역을 보고, 같은 질문을 옮긴다

$$\begin{bmatrix} 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 1 & 1 & 1 \end{bmatrix} \times \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix} = \boxed{3}$$

입력의 3 × 3 영역 필터의 가중치 한 위치의 반응

입력의 3 × 3 영역

수업용 손계산 · 실제 학습에서는 필터 값 자체가 바뀐다.

수업용 재구성 · 논문 원문 그림과 구별

Read & think 학습 후 필터를 관찰하는 것과, 사람이 의미 있는 필터를 미리 넣는 것은 다릅니다.


CNN / CHANNELS & LEARNED FILTERS

3 MIN

RGB 세 장을 따로 분류하는 것이 아니다.

하나의 필터는 연결된 입력 채널을 함께 보고, 하나의 출력 특징 맵을 만듭니다.

RGB는 입력 채널, 필터 개수는 출력 채널



입력: 3개 채널


출력: 여러 특징 맵

하나의 $11 \times 11 \times 3$ 필터 → 한 출력 채널

수업용 재구성 · 논문 원문 그림과 구별

ORIGINAL PAPER

p. 6 · Figure 3 ↗



원문 PDF 직접 캡처 · 주변 본문/캡션 생략 · 아래 설명은 수업용 해설

원문에서 관찰

색 대비와 방향성 같은 서로 다른 패턴이 보입니다.

넘겨짚지 않기

이 그림은 첫 층의 가중치입니다. 특정 입력의 특징 맵이나 “모델의 생각” 전체가 아닙니다.

Read & think 필터·특징 맵·채널은 같은 말이 아닙니다. “무엇의 그림인가?”를 먼저 확인합니다.

함께 읽기 이 그림의 한 칸을 “고양이 확률”이라고 부를 수 있을까요?

가중치 공유는, 같은 질문을 재사용하는 약속.

위치마다 별도의 탐지기를 만들지 않는다는 구조적 가정입니다.

절약하는 것

공간 위치가 늘어도 같은 필터를 재사용합니다. 학습해야 할 규칙의 수를 줄입니다.

얻는 성질과 한계

단서를 다른 위치에서도 찾기 쉽지만, padding·stride·pooling·분류기 때문에 완전한 위치 불변성이 자동 보장되지는 않습니다.

공간 위치마다 새 가중치가 필요한가?

같은 필터를 재사용하는 합성곱

$$(3 \times 3 \times 1 + 1) \times 8 = 80$$

같은 출력 크기에 완전연결을 사용한다면

$$(28 \times 28 + 1) \times (28 \times 28 \times 8)$$

수업용 비교 · 두 모델의 성능이 같다는 뜻은 아니다.

수업용 재구성 · 논문 원문 그림과 구별

Read & think

적은 가중치와 같은 성능은 같은 말이 아닙니다. 구조의 가정이 과제에 맞는지 묻습니다.

깊이는 “새 필터를 더한다”보다 많은 일을 한다.

다음 층의 입력은 원본 이미지가 아니라, 앞 층이 계산한 반응들입니다.

뒤쪽 층은 앞쪽 층의 반응을 입력으로 받는다



층을 쌓으면 한 반응에 영향을 주는 입력 범위도 커진다.

특정 채널에 사람이 아는 부품 이름이 반드시 붙는 것은 아니다.

수업용 재구성 · 논문 원문 그림과 구별

3 × 3, stride 1, dilation 1을 연속 적용하는 단순 예: 수용 영역 3 → 5 → 7

Read & think 더 넓은 영역을 조합할 수 있다는 설명과, 실제 의미를 배웠다는 증거를 구분합니다.

METHOD / READ THE ORIGINAL ARCHITECTURE


3 MIN

Figure 2는, 읽는 순서를 정하면 덜 복잡하다.

먼저 전체 경로, 그다음 층의 역할, 마지막으로 연결과 크기를 확인합니다.

ORIGINAL PAPER

p. 5 · Figure 2 ↗



원문 PDF 직접 캡처 · 주변 본문/캡션 생략 · 아래 설명은 수업용 해설

① 왼쪽 → 오른쪽

입력 → 합성곱 5개 → 완전연결 3개

② 위·아래 줄

두 GPU에 나눈 연결을 표현

③ 보조 연산

ReLU · 정규화 · pooling 위치 확인

Read & think 8개 “학습 가능한 층”이라는 표현을 모든 연산의 개수로 읽지 않습니다.

함께 읽기 pooling과 ReLU가 있는데 왜 8개 층이라고 할까요?

같은 구조를, 역할 중심으로 다시 그린다.

도식에서 읽은 관계를 자기 말로 설명하면, 숫자를 외우는 부담이 줄어듭니다.



층 묶음	확인할 설계	읽기 질문
합성곱	필터 크기·채널·stride·연결	어떤 범위의 어떤 입력을 함께 보는가?
pooling	창 크기·이동 간격	무엇을 남기고 공간 정보를 얼마나 줄이는가?
완전연결	입력을 모아 점수 생성	공간별 반응이 어떻게 클래스 점수가 되는가?

Read & think 이 재구성은 이해를 위한 요약입니다. 정확한 재현에는 원문과 구현의 세부 조건이 더 필요합니다.


METHOD / NONLINEARITY

3 MIN

ReLU: 신호를 바꾸는 작은 규칙의 큰 차이.

양수는 통과시키고 음수는 0으로 만듭니다. 선형 연산만 쌓는 것과 달라집니다.

값을 통과시키는 규칙이 학습을 바꾼다



수업용 재구성 · 논문 원문 그림과 구별

왜 비선형인가?

선형 변환만 연속 적용하면 전체도 하나의 선형 변환으로 합칠 수 있습니다.

학습의 관점

ReLU의 양수 구간은 입력이 커져도 포화되지 않습니다. 다만 음수 구간의 기울기는 0입니다.

논문에서 확인할 것

빠르다는 주장을 Figure 1의 축·범례·실험 조건으로 검토합니다.

Read & think

ReLU가 모든 학습 문제를 해결한다는 말 대신, 어떤 조건에서 어떤 개선을 보였는지 읽습니다.

METHOD / OVERLAPPING POOLING

2 MIN

Pooling: 주변의 강한 반응을 남긴다.

공간 크기를 줄이고, 작은 위치 변화에 덜 민감한 요약을 만들 수 있습니다.

max pooling

한 채널의 작은 영역에서 최댓값을 선택합니다. 필터를 새로 학습하는 연산은 아닙니다.


겹치는 창

창보다 이동 간격이 작으면 이웃 창이 같은 입력 일부를 봅니다.

잃는 것

정확한 위치와 일부 값이 사라집니다. 요약이 언제나 유리한 것은 아닙니다.

3 × 3 창을 2칸씩 이동: 영역이 겹친다



수업용 예제 · 같은 채널 안에서 주변 반응을 요약

수업용 재구성 · 논문 원문 그림과 구별

Read & think 논문의 선택: 창 3 × 3, stride 2. 개념을 이해한 뒤 비교 대상과 출력 크기를 확인합니다.

METHOD / LOCAL RESPONSE NORMALIZATION

2 MIN

LRN: 같은 위치의 다른 채널을 함께 본다.

주변 채널의 반응 크기를 이용해, 현재 반응의 규모를 조절하는 연산입니다.

01

현재 반응

한 위치·한 채널

02

이웃 채널 확인

반응의 제곱합

03

규모 조절

큰 주변 반응 → 큰 분모

01

직관

여러 채널이 동시에 크게 반응할 때
각 반응의 크기를 조절한다.

02

구별

배치 평균·분산을 사용하는
BatchNorm과 같은 연산이 아니다.

03

읽기 태도

2012년 논문의 설계 선택으로 읽고,
모든 CNN의 필수 요소로 일반화하지 않는다.

Read & think 수식의 복잡한 첨자를 보기 전에 “어떤 값을 무엇으로 나누는가?”를 이해합니다.

METHOD / DATA AUGMENTATION

2 MIN

증강: 라벨을 보존하는 변화부터 생각한다.

같은 대상을 다르게 보여 주어도 같은 정답을 요구하는 학습입니다.

01

위치와 반전

원문: crop과 좌우 반전.

대상이 조금 옮겨져도 같은 분류를 요구한다.

02

색과 조명

원문: RGB 변동을 이용한 색 변화.

수식 전에 변화의 목적부터 이해한다.

03

가정의 한계

잘린 이미지에도 정답 단서가 남는가?

뒤집기·회전 후에도 같은 라벨인가?

1주차와 연결

MNIST의 6을 크게 회전시켜 9처럼 만들면, “모든 변환이 라벨을 보존한다”는 가정이 깨집니다.

Read & think

훈련 증강과 평가 때 여러 crop의 예측을 평균하는 절차를 따로 기록합니다.

함께 읽기 훈련에서 여러 crop을 보이는 것과 시험에서 여러 crop을 평균하는 것은 같은 역할일까요?


METHOD / REDUCING CO-ADAPTATION

2 MIN

Dropout: 특정 조합에만 기대지 않도록.

학습 중 일부 활성화값을 무작위로 0으로 만들어, 다른 조합에서도 유용한 표현을 요구합니다.

일부 동료가 없어도 쓸 수 있는 단서



학습 시도 A

학습 시도 B

평가: 모두 사용

수업용 재구성 · 논문 원문 그림과 구별

어디에 쓰는가?

이 논문에서는 앞의 두 완전연결 층에 사용합니다.

무엇이 바뀌는가?

같은 가중치를 공유하면서, 매번 일부 활성화값을 가립니다. 뉴런을 영구 삭제하지 않습니다.

평가 때는?

모두 사용하되 크기 조절이 필요합니다. 원문의 평가 시 0.5 배율과 학습 때 보정하는 구현 관례를 구별합니다.

Read & think

양상블과 연결되는 직관은 유용하지만, 독립 모델 여러 개를 실제로 학습한 것과 같지는 않습니다.

SYMBOLS / CONVOLUTION

3 MIN

수식 ①: 필터와 특징 맵에 기호를 붙인다.

이미 설명한 “작은 영역을 곱해 더하기”를, 여러 채널과 위치로 확장합니다.

$$z_{o,i,j} = b_o + \sum_{c,u,v} W_{o,c,u,v} x_{c,i+u,j+v}$$

수업용 일반식 · stride 1의 유효 위치 · 딥러닝 구현의 cross-correlation 표기. 원문에 이 식이 그대로 실린 것은 아닙니다.

기호	이미 아는 개념	읽는 질문
c / o	입력 / 출력 채널	무엇을 함께 보고 어떤 지도를 만드는가?
u, v / i, j	창 안의 좌표 / 출력 위치	어디를 계산하고 어디에 기록하는가?
w / b	학습하는 필터 / 편향	위치를 옮겨도 같은 값이 재사용되는가?

Read & think 식을 외우기 전에 입력·출력·합산 대상·학습 변수를 찾습니다.

수식 ②: 정답 확률을 높인다는 말의 의미.

클래스 점수를 확률로 바꾸고, 정답에 낮은 확률을 주면 더 큰 손실을 받습니다.

$$p_k = \exp(s_k) / \sum_j \exp(s_j) \quad L = -\log p_y$$

수업용 표기 · 한 예시의 cross entropy. 원문 § 3.5의 정답 로그확률 최대화와 부호를 바꾼 동등한 목적.

01

정답 확률 0.8

$$-\log(0.8) \approx 0.223$$

02

정답 확률 0.2

$$-\log(0.2) \approx 1.609$$

03

학습과 평가의 차이

손실로 가중치를 학습하지만,
보고 표는 Top-1·Top-5 오류율

Read & think 확률을 출력한다는 것만으로 그 값이 잘 보정된 신뢰도라는 결론은 나오지 않습니다.

SYMBOLS / RETURN TO THE ORIGINAL EQUATION

2 MIN

수식 ③: LRN의 긴 첨자를, 질문으로 분해한다.

원문 수식을 보면서, 앞에서 이해한 연산이 어디에 적혀 있는지 찾습니다.

ORIGINAL PAPER

p. 4 · § 3.3 수식 ↗

$$b_{x,y}^i = a_{x,y}^i / \left(k + \alpha \sum_{j=\max(0,i-n/2)}^{\min(N-1,i+n/2)} (a_{x,y}^j)^2 \right)^\beta$$

원문 PDF 직접 캡처 · 주변 본문/캡션 생략 · 아래 설명은 수업용 해설

01

분자 a

현재 위치·채널의

ReLU 이후 반응

02

분모의 합

같은 위치의

주변 채널 반응 제곱합

03

상수와 지수

크기와 영향 범위를 조절하는

하이퍼파라미터

학습하는 가중치와, 검증 데이터로 선택하는 하이퍼파라미터를 구분하기

Read & think 모든 첨자를 외우는 대신, “주변 반응이 커지면 현재 출력은 어떻게 되는가?”에 답합니다.

함께 읽기 분자를 고정하고 주변 반응 제곱합만 키우면 출력은 어떻게 될까요?

EVIDENCE / A LEARNING-SPEED CLAIM


2 MIN

Figure 1: 축을 읽기 전에 결론을 읽지 않는다.

곡선을 보고 “더 좋다”라고 말하기 전에, 무엇을 측정했는지 확인합니다.

ORIGINAL PAPER

p. 3 · Figure 1 ↗



원문 PDF 직접 캡처 · 주변 본문/캡션 생략 · 아래 설명은 수업용 해설

먼저 축과 범례

가로는 epoch, 세로는 훈련 오류율입니다. 실선 ReLU와 점선 tanh를 비교합니다.

그다음 실험 조건

이 그림은 CIFAR-10의 4층 CNN 비교입니다. ImageNet 최종 모델의 시험 정확도 곡선이 아닙니다.

마지막 주장 범위

목표 훈련 오류율에 도달하는 속도를 비교합니다. 모든 모델에서 일정 배율로 빨라진다고 확대하지 않습니다.

Read & think 데이터 → 축 → 범례 → 비교 조건 → 결론 순서로 그래프를 읽습니다.

Table 1: 비교는 같은 열에서 시작한다.

첫 번째 표는 2010 시험 집합입니다. 지표를 고정한 뒤 차이를 계산합니다.

ORIGINAL PAPERp. 7 · Table 1 ↗

Model	Top-1	Top-5
<i>Sparse coding [2]</i>	47.1%	28.2%
<i>SIFT + FVs [24]</i>	45.7%	25.7%
CNN	37.5%	17.0%

원문 PDF 직접 캡처 · 주변 본문/캡션 생략 · 아래 설명은 수업용 해설

읽는 순서

데이터·분할 → 열의 지표 → 비교 행 → 수치 차이.

Top-5 비교 예

25.7% → 17.0%: 오류율이 **8.7%p** 낮아졌습니다.

해석의 한계

전체 방법의 성능 비교입니다. ReLU 하나만의 효과를 이 표에서 분리할 수는 없습니다.

퍼센트포인트와 상대 감소율은 다릅니다. 상대 감소율을 쓰면 분모도 명시합니다.

Read & think 같은 표의 개선을 읽되, 그 표가 분리하지 않은 원인까지 단정하지 않습니다.

Table 2: 15.3%의 주어를 정확히 읽는다.

같은 CNN이라는 이름 아래, 모델 수·추가 데이터·분할이 다릅니다.

ORIGINAL PAPER

p. 7 · Table 2 ↗

Model	Top-1 (val)	Top-5 (val)	Top-5 (test)
<i>SIFT + FVs [7]</i>	—	—	26.2%
1 CNN	40.7%	18.2%	—
5 CNNs	38.1%	16.4%	16.4%
1 CNN*	39.0%	16.6%	—
7 CNNs*	36.7%	15.4%	15.3%

원문 PDF 직접 캡처 · 주변 본문/캡션 생략 · 아래 설명은 수업용 해설

01

1 CNN

18.2%는 Top-5 **검증** 오류율.

시험 값은 빈칸입니다.

02

7 CNNs*

15.3%는 Top-5 **시험** 오류율.

여러 모델의 예측을 결합합니다.

03

별표 *

추가 ImageNet 사전학습 모델 포함.

이 행의 모든 모델이 같은 조건은 아닙니다.

Read & think

“AlexNet 단일 모델의 시험 오류율은 15.3%”라는 문장은 이 표를 정확히 설명하지 못합니다.

함께 읽기 별표·빈칸·val/test를 지우면, 같은 표에서 어떤 잘못된 이야기를 만들 수 있을까요?

EVIDENCE WORKSHOP / 2 MIN

2 MIN

짧은 활동: 표에 없는 결론을 찾아낸다.

다음 세 문장을 “가능 / 수정 필요 / 근거 부족”으로 분류하세요.

01

A

“Table 2의 7 CNNs*는
Top-5 시험 오류율 15.3%를 보였다.”

02

B

“모델 1개를 7개로 늘린 효과만으로
오류율이 18.2%에서 15.3%로 줄었다.”

03

C

“이 결과는 어떤 새 이미지 분포에서도
동일한 성능을 보장한다.”

토론 후 해설 열기

A는 조건을 포함한 기술입니다. B는 분할·사전학습·모델 구성이 함께 달라 원인 분리가 안 됩니다. C는 평가 범위를 넘어선 주장입니다.

Read & think 실험 표는 강한 근거이지만, 그 안에 없는 비교까지 대신해 주지는 않습니다.

구성 요소 비교: 좋아졌다는 말 뒤의 통제를 본다.

전체 모델 간 비교와, 한 선택의 효과를 분리하는 비교는 목적이 다릅니다.

원문에서 찾을 비교	확인할 교란 요인	우리가 남길 질문
ReLU / tanh (§ 3.1)	별로로 선택한 학습률	최종 오류와 학습 속도 중 무엇을 말하나?
2 GPU / 1 GPU (§ 3.2)	커널 수·연결도 함께 다름	GPU 개수만 바꾼 실험인가?
겹침 / 비겹침 pooling (§ 3.4)	창 크기, 같은 출력 크기	어떤 설정을 고정했는가?
중간 conv 층 제거 (§ 7)	깊이·계산·표현이 함께 변함	깊이가 늘수록 항상 좋다는 증거인가?

Read & think 논문이 보고한 관찰을 인정하면서, 인과적으로 말할 수 있는 범위를 따로 적습니다.

EVIDENCE / QUALITATIVE PREDICTIONS

2 MIN

Figure 4 왼쪽: 숫자 뒤에 어떤 실패가 있는가?

실제 예측 예시를 보되, 몇 장의 사례를 전체 데이터의 통계로 바꾸지 않습니다.

ORIGINAL PAPER

p. 8 · Figure 4 · 왼쪽 ↗



원문 PDF 직접 캡처 · 주변 본문/캡션 생략 · 아래 설명은 수업용 해설

무엇이 표시되었나?

시험 이미지, 상위 후보, 정답 라벨과 그에 해당하는 막대를 확인합니다.

무엇을 질문할까?

대상이 여러 개면 무엇을 분류해야 할까? 비슷한 범주끼리 헷갈리는가?

무엇은 알 수 없나?

선택된 예시만으로 오류의 빈도나 모든 실패 유형을 추정하기는 어렵습니다.

Read & think 정성 분석은 질문을 풍부하게 하고, 정량 평가는 그 질문의 빈도와 크기를 확인합니다.

EVIDENCE / REPRESENTATION & NEIGHBORS


2 MIN

Figure 4 오른쪽: 모델은 무엇을 비슷하다고 보나?

픽셀의 닮음과, 학습된 표현 공간에서의 닮음은 다를 수 있습니다.

ORIGINAL PAPER

p. 8 · Figure 4 · 오른쪽 ↗



원문 PDF 직접 캡처 · 주변 본문/캡션 생략 · 아래 설명은 수업용 해설

첫 열과 나머지 열

시험 이미지에 대해 마지막 은닉층 표현이 가까운 훈련 이미지를 찾습니다.

관찰할 것

자세나 배경이 달라도 비슷한 대상이 모이는지 봅니다.

주장의 경계

이웃 이미지가 그럴듯하다는 사실은 사람과 같은 의미 이해나 배경 무시를 증명하지 않습니다.

Read & think 시각화는 표현을 조사하는 도구입니다. 모델이 왜 판단했는지 완전히 설명하는 증명은 아닙니다.

FINAL PASS / DISCUSSION

3 MIN

결론은, 처음의 질문으로 돌아가 읽는다.

AlexNet의 마지막 본문 절은 Conclusion이 아니라 § 7 Discussion입니다.

ORIGINAL PAPER

p. 8 · § 7 제목 ↗

7 Discussion

원문 PDF 직접 캡처 · 주변 본문/캡션 생략 · 아래 설명은 수업용 해설

01

무엇을 지지했나

이 설정의 큰 CNN을 지도학습으로 학습해
해당 분류 과제에서 강한 결과를 얻었다.

02

어디까지 말할 수 있나

특정 데이터·학습·평가 조건의 결과다.
깊이의 유용성이 무한한 깊이의 보장은 아니다.

03

무엇을 열어 두었나

더 큰 모델·데이터·계산,
영상의 시간 정보 등 후속 질문이 남는다.

Read & think

초록에서 만든 주장 목록에 돌아가, 확인한 것과 남은 것을 표시합니다.

함께 읽기 “더 큰 모델이 가능하다”와 “더 크게 만들면 항상 낫다”는 왜 다른 말일까요?

MY READING NOTE / FOUR QUESTIONS

1 MIN

마지막 한 페이지는, 저자의 요약이 아닌 나의 정리.

사용한 용어의 수보다, 근거와 미해결 질문이 얼마나 선명한지가 중요합니다.

01

저자가 말하고자 하는 것

이 논문을 한 문장으로 설명한다.
주장의 적용 범위를 함께 적는다.

02

연구에서 중요한 요소

결과에 중요하다고 본 선택 2-3개.
각각 근거 위치를 붙인다.

03

이해가 안 되는 부분

단어 대신 질문으로 적는다.
어떤 정보가 있으면 풀리는가?

04

추가로 공부하고 싶은 부분

다음에 읽을 개념·논문·실험.
구체적인 첫 행동을 정한다.

Read & think 이 네 칸이 채워지면, 완벽히 이해하지 못했어도 다음 읽기를 시작할 수 있습니다.

INDIVIDUAL WORK / 3 MIN

3 MIN

3분, AlexNet을 내 언어로 적어 본다.

화면의 빈칸을 공책이나 별도 읽기 기록지에 옮겨 적으세요.

01 저자의 핵심 메시지

이 논문은 _____라는 조건에서 _____를 보여 주었다.

02 중요한 요소와 근거

내가 고른 요소: _____ / 근거: § ____, Figure·Table ____

03 이해가 안 되는 부분

나는 _____가 왜/어떻게 _____인지 아직 모르겠다.

04 더 공부할 것

다음에는 _____를 읽거나 _____를 비교해 보겠다.

Read & think 2분 개인 작성 + 1분 짝에게 핵심 주장과 아직 남은 질문 설명.

EXAMPLE / ONE POSSIBLE READING NOTE

2 MIN

좋은 정리의 예: 확신과 질문을 함께 남긴다.

정답지가 아니라, 근거를 붙이고 모르는 점을 구체화하는 예입니다.

01

말하고자 하는 것

큰 CNN의 가능성을 구조·학습·평가를 묶어 보여 주었다.

근거: § 1, § 6, § 7

02

중요한 요소

공유·계층 구조, 학습 가능성, 과적합 억제.

근거: Figure 2, § § 3-5

03

아직 모르는 것

224 입력과 도식의 55 크기는 어떤 padding으로 맞출까?

다음 확인: 원문·원 구현의 차이

04

더 공부할 것

깊이를 늘릴 때 최적화가 어려워지는 이유.

다음 읽기: ResNet의 문제 정의와 비교 실험

Read & think 계산이 안 맞으면 몰래 숫자를 고치지 말고, 원문·도식·구현의 차이를 질문으로 남깁니다.

TAKE THIS METHOD WITH YOU

1 MIN

다음 논문에서도, 같은 순서로 묻는다.

개념을 이해하고, 수식으로 확인하고, 실험이 지지하는 범위까지 말하기.



오늘 함께 읽은 원문

Alex Krizhevsky, Ilya Sutskever, Geoffrey E. Hinton (2012)
ImageNet Classification with Deep Convolutional Neural Networks
 Advances in Neural Information Processing Systems 25

[NeurIPS 공식 PDF 열기 ↗](#) · [논문 페이지 ↗](#)

원문 캡처: Figures 1-4, Tables 1-2, § 3.3 수식, 제목·짧은 구절. 한국어 설명·개념도·활동은 수업용 재구성입니다. 전체 캡처 출처와 좌표: assets/alexnet/provenance.json

Read & think 출구 질문: AlexNet의 주장 하나와 근거 하나, 아직 모르는 질문 하나를 말할 수 있나요?