

VAE ① 잠재변수로 이미지 생성하기

AE와 VAE의 차이를 확률 분포 관점에서 설명한다.
재매개화와 ELBO 손실을 올바르게 구현한다.
MNIST 재구성·prior 샘플·잠재 보간을 구분한다.




IMAGE
↔ LATENT

00-02분 · 이번 주에 만들 결과물 확인

90분 수업 지도

- 01 00-05 도입 · 05-20 개념 · 20-35 수식과 손계산
- 02 35-50 구현 설계 · 50-75 실습 · 75-85 분석
- 03 85-90 회고 · 부록과 자율 과제는 수업 이후

90 MIN / 개념 45 + 실습 25 + 분석·회고 20

02-05분 · 실습 노트북 열기

분류에서 생성으로

$z \sim \text{prior}$

decoder


이미지 분포

샘플 x

- 01 분류기는 이미지가 어떤 클래스인지 예측한다.
- 02 생성 모델은 데이터의 분포를 학습하려 한다.
- 03 VAE는 관측 x 와 숨은 변수 z 의 관계를 모델링한다.

05-20분

Autoencoder 복습



- 01 encoder가 입력을 작은 벡터로 압축한다.
- 02 decoder가 그 벡터에서 입력을 복원한다.
- 03 재구성만 잘해도 임의의 z 가 좋은 이미지를 만든다는 보장은 없다.

05-20분

VAE의 encoder는 분포를 만든다

- 01 입력마다 μ 와 $\log \sigma^2$ 를 출력한다.
- 02 $q\varphi(z|x)$ 를 diagonal Gaussian으로 둔다.
- 03 z 한 점 대신 가능한 잠재 표현의 분포를 학습한다.

$$q\varphi(z|x) = N(\mu(x), \text{diag}(\sigma^2(x)))$$

05-20분

prior와 posterior

- 01 prior $p(z)$ 는 입력을 보기 전의 가정이다.
- 02 posterior $p(z|x)$ 는 관측 후의 분포다.
- 03 $q\varphi(z|x)$ 는 posterior를 대신하는 근사 분포다.

$$p(z)=N(0,I), q\varphi(z|x)\approx p\theta(z|x)$$

05-20분

decoder도 확률 모델

- 01 decoder는 $p_{\theta}(x|z)$ 의 파라미터를 출력한다.
- 02 Bernoulli 모델이라면 픽셀별 logits를 출력한다.
- 03 sigmoid 후 값은 각 픽셀의 1 확률이다.

decoder(z) → logits → sigmoid → pixel probability

05-20분

두 요구의 균형

- 01 reconstruction은 입력 정보를 z 에 담도록 한다.
- 02 KL은 q 가 prior에서 지나치게 멀어지는 것을 억제한다.
- 03 둘의 균형이 재구성과 생성에 영향을 준다.

잘 복원하기 + prior와 연결되는 잠재 공간

05-20분

샘플링과 미분의 문제

- 01 z 를 무작정 무작위 추출하면 gradient 경로를 설명하기 어렵다.
- 02 외부 잡음 ϵ 를 뽑고 $\mu \cdot \sigma$ 로 변환한다.
- 03 랜덤성은 ϵ , 학습 가능한 경로는 $\mu \cdot \sigma$ 에 둔다.

$$z = \mu + \sigma \odot \epsilon, \epsilon \sim N(0, I)$$

05-20분

주변 우도가 어려운 이유

- 01 $p_{\theta}(x)$ 는 가능한 모든 z 의 기여를 적분한다.
- 02 복잡한 decoder에서는 이 적분을 직접 계산하기 어렵다.
- 03 계산 가능한 하한을 최적화한다.

$$\log p_{\theta}(x) = \log \int p_{\theta}(x|z)p(z) dz$$

20-35분

ELBO의 두 항

- 01 재구성 기대 로그우도는 데이터를 설명하도록 한다.
- 02 $KL(q \parallel p)$ 는 근사 분포와 prior 차이를 측정한다.
- 03 ELBO를 최대화하면 $\log p(x)$ 의 하한을 높인다.

$$ELBO = E_q[\log p_{\theta}(x|z)] - KL(q_{\phi}(z|x) \parallel p(z))$$

20-35분

하한과 정확한 차이

- 01 $\log p_{\theta}(x)$ 는 ELBO에 posterior KL을 더한 값이다.
- 02 KL은 0 이상이라 ELBO가 하한이 된다.
- 03 prior KL과 posterior KL을 혼동하지 않는다.

$$\log p_{\theta}(x) = \text{ELBO} + \text{KL}(q_{\phi}(z|x) \parallel p_{\theta}(z|x))$$

20-35분

Gaussian KL 닫힌식

- 01 prior는 표준정규, q는 대각 Gaussian이다.
- 02 μ^2 , $\exp(\logvar)$, $\logvar$ 로 계산한다.
- 03 잠재 차원별 값을 합하고 배치 평균한다.

$$KL = \frac{1}{2} \sum_j [\mu_j^2 + \exp(\logvar_j) - 1 - \logvar_j]$$

20-35분

log variance에서 표준편차로

- 01 logvar는 $\log \sigma^2$ 이다.
- 02 variance는 $\exp(\logvar)$ 이다.
- 03 standard deviation은 $\exp(0.5 \times \logvar)$ 이다.

$$z = \mu + \exp(0.5 \times \logvar) \odot \text{randn_like}(\mu)$$

20-35분


손실 reduction을 맞추기

- 01 reconstruction은 픽셀 합, KL은 잠재 차원 합이다.
- 02 두 항을 샘플별로 만든 뒤 배치 평균한다.
- 03 픽셀 평균으로 바꾸면 KL의 상대적 세기가 달라진다.

$$\text{loss} = \text{mean_B}(\text{recon_sum_pixels} + \text{KL_sum_latents})$$

20-35분

오늘의 MLP VAE



- 01 encoder는 784→256 은닉 표현을 만든다.
- 02 μ head와 logvar head가 각각 latent_dim을 출력한다.
- 03 decoder는 latent_dim→256→784 logits를 출력한다.

35-50분

BCEWithLogits로 수치 안정성

logits를 그대로 손실 함수에 넣는다.

시각화 시에만 sigmoid를 적용한다.

target은 0

1 범위여야 한다.

```
recon =  
F.binary_cross_entropy_with_logits(  
    logits, x, reduction='none')  
recon = recon.flatten(1).sum(1)
```

35-50분

AE와 VAE를 비교할 때

- 01 같은 데이터와 유사한 은닉 폭을 사용한다.
- 02 AE는 deterministic z , VAE는 $\mu \cdot \log \text{var}$ 와 샘플링을 쓴다.
- 03 재구성만으로 생성 모델 전체를 평가하지 않는다.

reconstruction quality $\neq$ prior sample quality

35-50분

평가의 랜덤성 관리

- 01 μ 를 넣은 재구성은 반복 비교하기 쉽다.
- 02 ELBO 평가의 reconstruction 기대값은 샘플로 근사한다.
- 03 같은 seed·같은 표본으로 조건 간 변동을 줄인다.

μ reconstruction / stochastic ELBO estimate 구분

35-50분

검증할 불변량

- 01 $\mu=0$, $\log\text{var}=0$ 에서 KL이 0이어야 한다.
- 02 reparameterization 출력 shape가 μ 와 같아야 한다.
- 03 backward 후 μ 와 $\log\text{var}$ 경로에 gradient가 있어야 한다.

$KL \geq 0$ / finite loss / gradient path

35-50분

LAB 1 · 손실과 재매개화

- 01 practice §1–3: MNIST 범위와 shape를 확인한다.
- 02 Gaussian KL의 두 손계산 사례를 검사한다.
- 03 ε 샘플의 평균·분산과 gradient를 확인한다.

50–58분 / 산출물: KL 검사 + 표본 통계

50–75분 · practice.ipynb와 함께 진행

LAB 2 · VAE 학습

- 01 practice §4: recon·KL·total을 따로 기록한다.
- 02 최고 validation negative ELBO를 보관한다.
- 03 학습 곡선의 세 향을 분리해서 읽는다.

58–69분 / 산출물: 3개 손실 곡선

50–75분 · practice.ipynb와 함께 진행

LAB 3 · 세 종류의 이미지

- 01 practice §5–7: 원본· μ 재구성을 나란히 그린다.
- 02 prior $N(0, I)$ 에서 z 를 뽑아 이미지를 생성한다.
- 03 두 입력의 μ 사이를 선형 보간한다.

69–75분 / 산출물: 재구성·prior 샘플·보간

50–75분 · practice.ipynb와 함께 진행

VAE 그림이 흐릿한 이유

- 01 제한된 모델 용량과 학습 예산이 영향을 준다.
- 02 픽셀별 조건부 모델이 평균적인 출력을 선호할 수 있다.
- 03 KL과 재구성의 균형도 영향을 준다.

흐릿함의 원인은 하나가 아니다

75-85분

좋은 재구성과 좋은 생성

- 01 재구성은 특정 입력에 조건화한 z 를 사용한다.
- 02 prior 샘플은 잠재 공간의 다른 영역에 놓일 수 있다.
- 03 두 결과를 별도 격자로 평가한다.

$q(z|x)$ 에서 복원 / $p(z)$ 에서 생성

75-85분

잠재 공간 scatter 읽기

- 01 입력별 μ 를 2차원 평면에 찍는다.
- 02 라벨 색은 시각화용이며 학습 loss에 사용하지 않는다.
- 03 군집의 분리는 분류 성능이나 독립 요인을 보장하지 않는다.

$\mu(x)$ 의 지도는 q 전체와 다르다

75-85분

출구 퀴즈

- 01 Q1. $\log\text{var}=0$ 이면 표준편차는?
- 02 Q2. 생성 시 z 는 encoder와 prior 중 어디서 뽑을까?
- 03 Q3. negative ELBO에서 KL의 부호는?

분포 / 생성 경로 / 목적함수

85-90분

다음: 잠재 공간을 조절하기

- 01 β 로 재구성과 KL의 상대 가중치를 바꾼다.
- 02 조건 라벨을 주어 원하는 숫자를 생성한다.
- 03 같은 손실 척도와 같은 z 로 비교한다.

자율 과제: KL·재매개화·latent 차원

85-90분

부록 · Jensen으로 하한 만들기

- 01 $q(z|x)$ 를 곱하고 나눠 기대값 형태로 바꾼다.
- 02 $\log E_q[p(x,z)/q]$ 에 Jensen 부등식을 적용한다.
- 03 $E_q[\log p(x,z) - \log q]$ 를 얻는다.

$$\log E[f] \geq E[\log f]$$

수업 외 심화

부록 · KL은 거리일까

- 01 KL은 비음수지만 일반적으로 대칭이 아니다.
- 02 $KL(q \parallel p)$ 와 $KL(p \parallel q)$ 는 다르다.
- 03 삼각부등식을 만족하는 일반적인 거리로 취급하지 않는다.

$$KL(q \parallel p) \neq KL(p \parallel q)$$

수업 외 심화

부록 · 관측 모델 바꾸기

- 01 Gaussian decoder는 실수값 관측에 쓸 수 있다.
- 02 고정 분산 Gaussian의 NLL은 MSE와 연결된다.
- 03 분산 선택에 따라 reconstruction 항의 스케일이 바뀐다.

likelihood 선택 → loss 형태와 스케일

수업 외 심화

부록 · latent 차원의 영향

- 01 너무 작으면 정보를 충분히 담기 어렵다.
- 02 크게 해도 일부 차원을 사용하지 않을 수 있다.
- 03 차원별 KL과 μ 의 변동을 함께 관찰한다.

nominal dimension $\neq$ used dimension

수업 외 심화

부록 · stochastic reconstruction

- 01 같은 x 에서도 z 가 달라져 복원이 달라질 수 있다.
- 02 μ 를 쓰면 대표적인 복원을 확인할 수 있다.
- 03 μ decoding은 x 의 정확한 조건부 평균과 일반적으로 다르다.

$$\text{decoder}(E[z]) \neq E[\text{decoder}(z)]$$

수업 외 심화

부록 · latent grid

- 01 2차원 z 의 좌표를 격자로 골라 decode한다.
- 02 prior 밀도가 낮은 바깥 영역은 낮은 결과를 낼 수 있다.
- 03 정규분포 분위수 격자도 사용할 수 있다.

$z_1 \cdot z_2$ 좌표 → 이미지 지도

수업 외 심화

부록 · 자율 과제 방향


- 01 reparameterize와 KL을 빈칸부터 구현한다.
- 02 latent_dim 2와 8을 같은 예산으로 비교한다.
- 03 재구성과 prior 샘플을 각각 설명한다.

수치 검사 + 시각화 + 해석


수업 외 심화

시각 보충 · 학습과 생성의 두 경로

재구성 경로: 입력 정보 사용




prior 생성 경로: 특정 입력 없음



수업 외 복습 · 해당 개념 설명 시 함께 활용 가능


시각 보충 · 재매개화의 gradient 경로



gradient는 $\mu \cdot \log \text{var}$ 경로를 따라 encoder로 흐른다.

수업 외 복습 · 해당 개념 설명 시 함께 활용 가능

시각 보충 · reduction의 단위



recon을 픽셀 평균으로 바꾸면 상대 가중치가 784배 달라진다.

수업 외 복습 · 해당 개념 설명 시 함께 활용 가능

시각 보충 · 조건부 생성 격자의 축

개념도 · 실제 생성 이미지 아님

	z_0 고정	z_1 고정	z_2 고정	z_3 고정	z_4 고정
$y=0$	<code>dec(z0, 0)</code>	<code>dec(z1, 0)</code>	<code>dec(z2, 0)</code>	<code>dec(z3, 0)</code>	<code>dec(z4, 0)</code>
$y=1$	<code>dec(z0, 1)</code>	<code>dec(z1, 1)</code>	<code>dec(z2, 1)</code>	<code>dec(z3, 1)</code>	<code>dec(z4, 1)</code>
$y=2$	<code>dec(z0, 2)</code>	<code>dec(z1, 2)</code>	<code>dec(z2, 2)</code>	<code>dec(z3, 2)</code>	<code>dec(z4, 2)</code>
$y=3$	<code>dec(z0, 3)</code>	<code>dec(z1, 3)</code>	<code>dec(z2, 3)</code>	<code>dec(z3, 3)</code>	<code>dec(z4, 3)</code>

아래로: 같은 z , 다른 y / 옆으로: 같은 y , 다른 z

수업 외 복습 · 해당 개념 설명 시 함께 활용 가능

읽을거리와 출처

- 01 Auto-Encoding Variational Bayes · Kingma & Welling
- 02 β -VAE · Higgins et al.
- 03 BCE with logits · 공식 API

원문 링크는 발표자 노트와 주차별 README에 수록

생각하기 → 손으로 계산하기 → 코드로 검증하기